Guia do Professor

IA Aplicada à Engenharia Química — da criação do curso à condução da última aula

Luis Gonzaga Sales Vasconcelos — UFCG/UAEQ

2026

Sumário

Ementa e projeto pedagógico **3**
1. Identificação . . . 3
2. Justificativa . . . 3
3. Objetivo geral . . . 4
4. Competências e evidência de avaliação . . . 4
5. Conteúdo programático . . . 6
6. Metodologia . . . 6
7. Avaliação . . . 7
8. Recursos . . . 7
9. Bibliografia de referência . . . 8
10. Como usar este guia . . . 8

Cronograma — uma página por aula **9**
Visão geral . . . 9
Aula 01 — Introdução à IA na Engenharia Química . . . 10
Aula 02 — Estrutura e Tratamento de Dados Industriais . . . 11
Aula 03 — Engenharia de Features Industriais . . . 12
Aula 04 — Análise Exploratória e Visualização (EDA) . . . 13
Aula 05 — Machine Learning Supervisionado . . . 13
Aula 06 — Avaliação e Validação de Modelos . . . 14
Aula 07 — Conceito e Projeto de Soft-Sensors . . . 15
Aula 08 — Laboratório Prático 1 — Soft-Sensor . . . 15
Aula 09 — Introdução às Redes Neurais Artificiais . . . 16
Aula 10 — Laboratório Prático 2 — Redes Neurais . . . 17
Aula 11 — Modelagem Híbrida e Caixa Cinza . . . 17
Aula 12 — Laboratório Prático 3 — Modelo Híbrido . . . 18
Aula 13 — Dinâmica de Processos e Séries Temporais . . . 19
Aula 14 — LSTM para Predição Dinâmica . . . 20
Aula 15 — Otimização de Processos com IA . . . 20
Aula 16 — Visão Conceitual de Controle Avançado . . . 21
Aula 17 — Manutenção Preditiva e RUL . . . 22
Aula 18 — Detecção e Diagnóstico de Anomalias . . . 22
Aula 19 — Interpretabilidade e Explicabilidade (XAI) . . . 23
Aula 20 — Gêmeos Digitais, IIoT e IA Generativa . . . 24
Aula 21 — Desafios de Implantação e Governança de IA . . . 24
Aula 22 — Ética, Segurança Industrial e Responsabilidade . . . 25
Aula 23 — O Engenheiro Químico do Futuro . . . 26

Aula 24 — Checkpoint e Mentoria do Projeto Prático . . . 26
Aula 25 — Oficina de Desenvolvimento I . . . 27
Aula 26 — Oficina de Desenvolvimento II . . . 27
Aula 27 — Consolidação dos Resultados do Projeto Integrador . . . 28
Aula 28 — Ensaio e Ajustes de Apresentação . . . 29
Aula 29 — Apresentações Finais I . . . 29
Aula 30 — Apresentações Finais II e Encerramento do Curso . . . 30

Rubricas de avaliação **31**
1. Princípios que valem para todos os instrumentos . . . 31
2. Laboratório 1 — Soft-sensor da coluna de destilação . . . 31
3. Laboratório 2 — MLP com Keras . . . 32
4. Laboratório 3 — Modelo híbrido (caixa-cinza) . . . 33
5. Projeto integrador (aulas 24–30) . . . 33
6. Tarefas pós-aula . . . 34
7. Política de uso de IA generativa . . . 34
8. Fechamento da nota . . . 35

Armadilhas **36**
1. Armadilhas verificadas no próprio material . . . 36
2. Riscos de condução . . . 38
3. Falhas de desenho a corrigir se você adotar o material . . . 39
4. Checklist antes do primeiro dia . . . 39

Ementa e projeto pedagógico

IA Aplicada à Engenharia Química · 30 aulas × 100 min = 50 h Graduação em Engenharia Química · ênfase em Engenharia de Sistemas de Processos

> Este documento é a peça de abertura do Guia do Professor. Ele descreve **o que** a disciplina ensina e **por que** nessa ordem. O detalhamento aula por aula está em `cronograma.md`; a avaliação, em `rubricas.md`.

---

1. Identificação

Campo	Valor
Disciplina	IA Aplicada à Engenharia Química
Carga horária	50 h (30 encontros de 100 min)
Nível	Graduação, a partir do 6º período
Pré-requisitos	Cálculo I, Álgebra Linear, Balanço de Massa e Energia, Fenômenos de Transporte
Pré-requisitos **dispensáveis**	Programação e Machine Learning — o curso constrói os dois do zero
Laboratório	Google Colab (navegador), sem instalação local
Vagas típicas por turma	20 a 40 alunos, em duplas nos laboratórios

O que o aluno precisa saber antes

Lógica de programação básica (variável, laço, função) e o conceito de balanço de massa/energia. **Não** é exigido curso prévio de estatística avançada, Python ou machine learning. A Aula 01 começa no `pd.read_csv()` e o Módulo 2 constrói regressão do zero.

Se a turma for heterogênea em programação — o caso mais comum —, veja o capítulo `armadilhas.md` antes da primeira aula: há uma estratégia de pareamento que resolve isso sem criar duas disciplinas.

---

2. Justificativa

O engenheiro químico formado hoje vai trabalhar com dados que já existem na planta — PIMS, SCADA, historian — mas raramente recebeu formação para transformá-los em decisão. Os cursos tradicionais ensinam

modelagem fenomenológica e controle clássico; a literatura de machine learning ensina algoritmos com exemplos de preço de imóvel e dígitos escritos à mão.

O resultado é um vão previsível: o profissional sabe que "IA resolve", não sabe onde ela falha, e não consegue julgar se um modelo entregue por terceiros é confiável.

Esta disciplina ocupa exatamente esse vão. Cada algoritmo entra acompanhado do problema de processo que ele resolve e do modo como ele engana quem não olha — vazamento de dados, overfitting que passa no gabarito, modelo que só funciona na faixa de treino.

A escolha de projeto que sustenta o curso

Quatro decisões de desenho explicam o comportamento do curso inteiro:

1. **Um processo, muitas tarefas.** As aulas 04, 05, 07, 08 e 09 usam o *mesmo* dataset de coluna de destilação com 30 dias. Trocar de dataset a cada aula ensina ferramenta; manter o processo ensina método — o aluno vê a mesma variável sendo explorada, prevista, transformada em soft-sensor e depois modelada por rede neural.
2. **Dados sintéticos com seed fixa.** Cada dataset é gerado com `seed=42` e fenômenos plantados de propósito (NaN, outliers, drift, falha de sensor). O aluno investiga um defeito que existe por construção, e o professor pode reproduzir qualquer resultado.
3. **Laboratório antes de teoria nova.** Os três laboratórios (aulas 08, 10 e 12) vêm imediatamente depois do conceito que exercitam, não no fim do módulo.
4. **Aula de 100 min com estrutura fixa.** 10 min de abertura, 25 de teoria, 40 de prática, 15 de discussão, 10 de fechamento e tarefa. A previsibilidade libera carga cognitiva para o conteúdo.

---

3. Objetivo geral

Capacitar o aluno a **formular, construir, validar e criticar** soluções de aprendizado de máquina para problemas de engenharia de sistemas de processos — predição, soft-sensors, detecção de anomalias, manutenção preditiva, otimização e controle — reconhecendo os limites de cada modelo e as condições em que ele deixa de valer.

O verbo final não é "implementar": é **criticar**. Um engenheiro que sabe treinar um modelo e não sabe quando desconfiar dele é mais perigoso que um que nunca treinou.

---

4. Competências e evidência de avaliação

Cada competência abaixo é declarada junto com **o instrumento que a evidencia**. Competência sem instrumento é intenção, não currículo.

#	Competência	Evidenciada por
C1	Tratar série temporal industrial: faltantes, outliers, ruído, alinhamento de frequências	Lab 1 · tarefa da Aula 02

#	Competência	Evidenciada por
C2	Construir features com significado físico (lags, médias móveis, taxas) sem vazamento temporal	Tarefa da Aula 03 · projeto
C3	Escolher e justificar modelo por meio de validação adequada ao problema	Tarefa da Aula 06 · projeto
C4	Projetar um soft-sensor completo: variável-alvo, atraso, métrica, faixa de validade	**Lab 1**
C5	Treinar e diagnosticar rede neural (MLP) para regressão de processo	**Lab 2**
C6	Construir modelo híbrido caixa-cinza combinando conhecimento fenomenológico e dado	**Lab 3**
C7	Detectar e explicar anomalias de processo, distinguindo falha de mudança de regime	Tarefa da Aula 18 · projeto
C8	Comunicar resultado técnico para dois públicos: pares e gestão	Relatório executivo + pitch (Aulas 27–29)

Progressão cognitiva (Bloom)

A matriz abaixo é o esqueleto do curso. Ela mostra que a exigência cognitiva sobe por módulo, e não por aula isolada — o que evita a armadilha do curso que só "aplica" do começo ao fim.

Módulo	Aulas	Bloom dominante	O que o aluno faz
M1 — Fundamentos e Dados	01–04	Lembrar → Analisar	Reconhece a arquitetura de dados e investiga a qualidade
M2 — Aprendizado de Máquina	05–12	Aplicar → **Criar**	Treina, valida e constrói soft-sensor, MLP e híbrido
M3 — Modelagem Dinâmica	13–14	Compreender → Aplicar	Modela dependência temporal e projeta o LSTM
M4 — Otimização, Controle e Confiabilidade	15–18	Analisar → Criar	Otimiza, simula MPC, estima RUL, diagnostica anomalia
M5 — Ciclo de Vida do Modelo	19–23	**Avaliar**	Julga interpretabilidade, governança, ética e risco
M6 — Projeto Integrador	24–30	**Criar** e Avaliar	Executa e defende um projeto próprio de ponta a ponta

5. Conteúdo programático

M1 — Fundamentos e Dados (aulas 01–04). IA na engenharia química; a pirâmide de dados industriais (sensor → PLC → SCADA → PIMS); estrutura de séries temporais; qualidade de dados; engenharia de features; análise exploratória aplicada a processo.

M2 — Aprendizado de Máquina (aulas 05–12). Regressão linear e regularizada; árvores e ensembles; gradient boosting; validação cruzada e diagnóstico de over/underfitting; métricas por tipo de erro; conceito e projeto de soft-sensors; redes MLP; modelagem híbrida caixa-cinza; três laboratórios práticos com template e gabarito.

M3 — Modelagem Dinâmica (aulas 13–14). Resposta dinâmica, FOPDT, atraso de transporte; séries temporais; janelas deslizantes; LSTM para predição dinâmica.

M4 — Otimização, Controle e Confiabilidade (aulas 15–18). Otimização de processo com modelo substituto; MPC — conceito, horizonte, modelo de predição; manutenção preditiva e RUL; detecção e diagnóstico de anomalias (PCA, Isolation Forest, autoencoder).

M5 — Ciclo de Vida do Modelo (aulas 19–23). Interpretabilidade (SHAP); gêmeos digitais e IIoT; implantação, monitoramento de drift e governança (champion/challenger); ética, segurança industrial e responsabilidade técnica; o engenheiro químico do futuro.

M6 — Projeto Integrador (aulas 24–30). Mentoria, duas oficinas de desenvolvimento, consolidação de resultados, ensaio e apresentações finais.

---

6. Metodologia

Anatomia fixa da aula de 100 min

Bloco	Tempo	Função
Abertura	10 min	Pergunta-desafio que ancora o tema no processo
Teoria	25 min	Conceito mínimo necessário — não a literatura completa
Prática	40 min	Exercício guiado (20) + exercício em grupo (20)
Discussão e fechamento	15 min	O que o resultado significa, o que ele não prova
Tarefa	10 min	Transferência: mesmo método, outro processo

Três lentes pedagógicas

O material original usa três lentes para diversificar o formato. Vale a leitura crítica do que cada uma sustenta:

Lente	Uso legítimo	Cuidado
Bloom	Estruturar progressão cognitiva ao longo do curso	Sólido como espinha dorsal
Felder-Silverman	Garantir **variedade de formato** na mesma aula (ativo/reflexivo, visual/verbal, sequencial/global)	A evidência de que "ensinar conforme o estilo do aluno" melhora aprendizado é fraca. Use como checklist de variedade, não como diagnóstico do aluno
MBTI (NT/SJ)	Planejar estímulos diferentes: problema aberto (NT) e cronograma/checklist (SJ)	Validade psicométrica contestada. Trate como metáfora de design, nunca como classificação de estudante

A honestidade aqui importa: o curso não fica mais fraco por dizer que duas das três lentes são heurísticas de variedade. Fica mais defensável.

---

7. Avaliação

> **Proposta de composição.** Ajuste pesos e instrumentos à sua instituição — o que não deve mudar é o princípio: *a nota precisa vir de algo que o aluno faria num emprego*.

Instrumento	Peso sugerido	O que mede
Laboratórios 1, 2 e 3	30% (10% cada)	Execução técnica com entrega verificável
Projeto integrador	40%	Formulação do problema, validação, comunicação
Tarefas pós-aula	20%	Transferência para outro processo
Participação e discussão	10%	Julgamento crítico — especialmente nas aulas 19–23

Princípios

1. **Nota por decisão, não por acerto.** Um modelo com R^2 pior, mas com validação temporal correta, vale mais que um R^2 alto obtido com vazamento.
2. **Faixa de validade explícita.** Todo modelo entregue declara onde deixa de valer.
3. **Duas audiências.** O relatório executivo (2 páginas, para gestão) e o pitch de 12 min (para pares) avaliam competências diferentes.

Rubricas detalhadas por nível em `rubricas.md`.

---

8. Recursos

Recurso	Onde
26 notebooks prontos para Colab	`../notebooks/`
34 arquivos de dados sintéticos (seed 42)	`../dados/`
27 apresentações (PPTX + PDF, 265 slides)	`../slides/`
Dependências para execução local	`../requirements.txt`
Verificação de execução	seção “Verificação” do README

Todo o material tem DOI: **10.5281/zenodo.23649424**.

---

9. Bibliografia de referência

Agregada a partir das 30 aulas. As obras se repetem porque sustentam mais de um módulo.

Fundamentos de ML aplicado a processo - Géron, A. *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow*. O’Reilly. - McKinney, W. *Python for Data Analysis*. O’Reilly. - VanderPlas, J. *Python Data Science Handbook*. O’Reilly.

Engenharia química e sistemas de processos - Seborg, D. et al. *Process Dynamics and Control*. Wiley. - Fogler, H. S. *Elementos de Engenharia das Reações Químicas*. Pearson. - Shardt, Y. *Statistics for Chemical and Process Engineers*. Springer.

IA em processos industriais - Venkatasubramanian, V. *Artificial Intelligence in Chemical Engineering*. - Chiang, L.; Russell, E.; Braatz, R. *Fault Detection and Diagnosis in Industrial Systems*. Springer.

Didática e avaliação - Anderson, L.; Krathwohl, D. *A Taxonomy for Learning, Teaching and Assessing* (Bloom revisada). - Wiggins, G.; McTighe, J. *Understanding by Design*.

> A bibliografia completa por aula está em cada plano de aula. Esta lista é o núcleo que sustenta a disciplina inteira — comece por ela se estiver montando o curso do zero.

---

10. Como usar este guia

Se você vai **ministrar a disciplina inteira**: leia este documento, depois `cronograma.md`, e rode a verificação dos notebooks antes do primeiro dia.

Se você vai **usar só um módulo**: o Módulo 2 é autossuficiente e o mais replicável — são oito aulas com três laboratórios e não dependem do M1 além do tratamento de dados.

Se você quer **só uma aula**: o `cronograma.md` tem uma página por aula, com objetivo, sequência, materiais, dataset e tarefa. Uma página basta para dar a aula.

Antes de começar, leia `armadilhas.md`. Ele existe para você não repetir erros que já custaram aula.

Cronograma — uma página por aula

30 encontros de 100 min. Cada página traz objetivo, sequência didática, materiais, dados, apresentação e tarefa — o suficiente para dar a aula sem abrir o plano completo.

> **Como ler a coluna de dados.** A marca **reuso** indica que a aula **reutiliza o dataset** de uma aula anterior, de propósito: mesmo processo, tarefa cognitiva diferente. `Template` é o notebook com as lacunas para o aluno preencher; `Gabarito` é a versão resolvida, para o professor.

Visão geral

#	Aula	Módulo	Bloom
01	Introdução à IA na Engenharia Química	M1	Lembrar → Analisar
02	Estrutura e Tratamento de Dados Industriais	M1	Lembrar → Analisar
03	Engenharia de Features Industriais	M1	Lembrar → Analisar
04	Análise Exploratória e Visualização (EDA)	M1	Lembrar → Avaliar
05	Machine Learning Supervisionado	M2	Lembrar → Avaliar
06	Avaliação e Validação de Modelos	M2	Lembrar → Avaliar
07	Conceito e Projeto de Soft-Sensors	M2	Lembrar → Avaliar
08	Laboratório Prático 1 — Soft-Sensor	M2	Lembrar → Criar
09	Introdução às Redes Neurais Artificiais	M2	Lembrar → Analisar
10	Laboratório Prático 2 — Redes Neurais	M2	Lembrar → Criar
11	Modelagem Híbrida e Caixa Cinza	M2	Lembrar → Avaliar
12	Laboratório Prático 3 — Modelo Híbrido	M2	Lembrar → Criar

#	Aula	Módulo	Bloom
13	Dinâmica de Processos e Séries Temporais	M3	Lembrar → Analisar
14	LSTM para Predição Dinâmica	M3	Lembrar → Avaliar
15	Otimização de Processos com IA	M4	Lembrar → Criar
16	Visão Conceitual de Controle Avançado	M4	Lembrar → Analisar
17	Manutenção Preditiva e RUL	M4	Lembrar → Analisar
18	Detecção e Diagnóstico de Anomalias	M4	Lembrar → Criar
19	Interpretabilidade e Explicabilidade (XAI)	M5	Lembrar → Criar
20	Gêmeos Digitais, IIoT e IA Generativa	M5	Lembrar → Criar
21	Desafios de Implantação e Governança de IA	M5	Lembrar → Criar
22	Ética, Segurança Industrial e Responsabilidade	M5	Lembrar → Criar
23	O Engenheiro Químico do Futuro	M5	Lembrar → Criar
24	Checkpoint e Mentoria do Projeto Prático	M6	Lembrar → Criar
25	Oficina de Desenvolvimento I	M6	Lembrar → Criar
26	Oficina de Desenvolvimento II	M6	Aplicar → Avaliar
27	Consolidação dos Resultados do Projeto Integrador	M6	Lembrar → Criar
28	Ensaio e Ajustes de Apresentação	M6	Lembrar → Criar
29	Apresentações Finais I	M6	Lembrar → Criar
30	Apresentações Finais II e Encerramento do Curso	M6	Lembrar → Criar

27 das 30 aulas têm apresentação. As 3 sem deck são as 08, 10, 12 — laboratórios, conduzidos direto no notebook.

Aula 01 — Introdução à IA na Engenharia Química

M1 — Fundamentos e Dados · 100 min

Objetivo. Capacitar o aluno a situar a IA no contexto da Engenharia Química, reconhecer a arquitetura de dados industriais (PIMS/SCADA) e executar seu primeiro notebook Python para análise de dados de processo.

Recurso	Onde
Notebook	`aula01_exercicio.ipynb` · abrir no Colab
Dados	`aula01/coluna_destilacao_24h.csv`
Apresentação	pptx · pdf
Bloom	Lembrar → Analisar

Sequência didática.

1. Abertura (10 min) — O Engenheiro Químico na Era dos Dados
2. Teoria (25 min) — Indústria 4.0, PIMS/SCADA e o Papel dos Dados na Engenharia Química
3. Prática (40 min) — Seu Primeiro Notebook: Dados de Processo no Python
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *Se você pudesse perguntar qualquer coisa sobre os 10 mil sensores de uma planta de eteno, o que perguntaria?*

Tarefa pós-aula. Tarefa individual — "Meu Primeiro Mini-Relatório" Usando qualquer conjunto de dados de processo que você encontrar (sugestão: buscar na internet "chemical process dataset csv" ou usar dados de temperatura do seu dia a dia), crie um notebook no Google Colab que: 1. Importe pandas e carregue o dataset 2. Exiba as primeiras 10 linhas 3. Calcule estatísticas descritivas 4. Gere **1 gráfico** de uma variável ao longo do tempo 5. Escreva **3 bullet points** de observações técnicas (em português) **Trilha NT (desafio extra, opcional):** Tente encontrar um dataset com **pelo menos 5 variáveis** e […]

Aula 02 — Estrutura e Tratamento de Dados Industriais

M1 — Fundamentos e Dados · 100 min

Objetivo. Capacitar o aluno a carregar séries temporais industriais reais, identificar e tratar dados faltantes, outliers e ruídos de medição usando Pandas e métodos estatísticos.

Recurso	Onde
Notebook	`aula02_limpeza.ipynb` · abrir no Colab
Dados	`aula02/` — 5 arquivos (variantes A–D)
Apresentação	pptx · pdf
Bloom	Lembrar → Analisar

Sequência didática.

1. Abertura (10 min) — Dados Reais São Imperfeitos
2. Teoria (25 min) — Técnicas de Limpeza de Dados Industriais
3. Prática (40 min) — Mão na Massa: Limpando Dados Reais de Planta
4. Discussão e Fechamento (15 min)

5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *Se 30% dos dados de um sensor estão corrompidos, você descarta o sensor inteiro ou tenta recuperar? Qual o limite aceitável?*

Tarefa pós-aula. Tarefa individual — "Meu Pipeline de Limpeza" Baixe qualquer dataset público de processo (sugestões: Kaggle Chemical Process, UCI ML Repository, ou use o mesmo dataset da aula) e **intencionalmente corrompa** os dados adicionando: - 2% de NaN aleatórios - 3 outliers em uma variável à sua escolha - Ruído gaussiano com $\sigma = 2\%$ do valor médio Depois, crie um notebook que: 1. Carregue os dados corrompidos 2. Diagnostique os problemas (gráficos + tabelas) 3. Aplique o pipeline de limpeza (NaN → outliers → […]

Aula 03 — Engenharia de Features Industriais

M1 — Fundamentos e Dados · 100 min

Objetivo. Capacitar o aluno a transformar séries temporais brutas em features informativas — lags, médias móveis, taxas de variação — e alinhar bases com frequências de amostragem diferentes, preparando os dados para modelagem preditiva.

Recurso	Onde
Notebook	`aula03_features.ipynb` · abrir no Colab
Dados	`aula03/` — 4 arquivos
Apresentação	pptx · pdf
Bloom	Lembrar → Analisar

Sequência didática.

1. Abertura (10 min) — O Que o Passado Diz Sobre o Futuro?
2. Teoria (25 min) — Lags, Médias Móveis e Alinhamento Temporal
3. Prática (40 min) — Construindo Features para um Reator CSTR
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *Se a temperatura de topo agora afeta a composição daqui a 3 minutos, qual o lag ideal? E se o processo tiver atraso de transporte de 7 minutos?*

Tarefa pós-aula. Tarefa individual — "Feature Engineering para um Trocador de Calor" Você recebe um dataset de um **trocador de calor casco e tubo** com duas taxas de amostragem: - Variáveis de processo: `T_entrada`, `T_saida`, `vazao_fluido`, disponíveis a cada 30s - Variável de qualidade: `coeficiente_U` (coeficiente global de troca térmica, calculado semanalmente por balanço de energia), disponível 1x/semana (6 valores para 6 semanas) Sua missão: 1. Carregar e alinhar os dados (dica: o target é semanal — você precisa agregar as features por semana) 2. Criar pelo menos **6 features** diferentes […]

Aula 04 — Análise Exploratória e Visualização (EDA)

M1 — Fundamentos e Dados · 100 min

Objetivo. Capacitar o aluno a explorar visualmente bases de dados industriais usando Seaborn e Matplotlib — identificando distribuições, correlações, anomalias visuais e contando a história do processo através dos gráficos.

Recurso	Onde
Notebook	`aula04_eda.ipynb` · abrir no Colab
Dados	`aula04/coluna_destilacao_30dias.csv`
Apresentação	pptx · pdf
Bloom	Lembrar → Avaliar

Sequência didática.

1. Abertura (10 min) — Uma Imagem Vale Mil Dados
2. Teoria (25 min) — O Kit de Ferramentas da EDA
3. Prática (40 min) — EDA Completa de uma Planta de Destilação
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *Se o heatmap mostra correlação zero entre pressão e temperatura, mas a termodinâmica diz que P e T estão relacionadas (gás ideal), o que está errado? Dados? Feature? Escala?*

Tarefa pós-aula. Tarefa individual — "Relatório de EDA de um Processo" Escolha **um dataset industrial** (pode ser o mesmo da aula, o da tarefa anterior, ou um novo — Kaggle/UCI): Crie um notebook Colab com um relatório visual completo contendo: 1. **Capas:** Título, autor, fonte dos dados, período 2. **Seção 1 — Visão Geral:** `info()`, `describe()`, primeiras linhas 3. **Seção 2 — Distribuições:** histogramas + KDE para 5 variáveis, com comentários (quais são normais? quais são bimodais?) 4. **Seção 3 — Séries Temporais:** gráfico de 3 variáveis ao longo do tempo — identificar tendências e anomalias […]

Aula 05 — Machine Learning Supervisionado

M2 — Aprendizado de Máquina · 100 min

Objetivo. Capacitar o aluno a compreender os fundamentos da regressão supervisionada — da regressão linear simples ao ensemble com gradient boosting — treinando e comparando modelos para predição de variáveis de processo (composição, conversão, temperatura).

Recurso	Onde
Notebook	`aula05_ml_supervisionado.ipynb` · abrir no Colab
Dados	**reuso** · `aula04/coluna_destilacao_30dias.csv`
Apresentação	pptx · pdf
Bloom	Lembrar → Avaliar

Sequência didática.

1. Abertura (10 min) — Ensinando o Computador a Prever
2. Teoria (25 min) — Quatro Algoritmos, Uma Missão: Predizer
3. Prática (40 min) — Treinando e Comparando 4 Modelos
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *Se uma árvore de decisão pode desenhar 'degraus' para ajustar qualquer curva, por que não usamos árvores gigantes com profundidade 1000?*

Tarefa pós-aula. Tarefa individual — "Comparando Modelos para o CSTR" Usando o dataset do **reator CSTR** (features + conversão da Aula 3), você deve: 1. Treinar os mesmos 4 modelos (LinearRegression, DecisionTree, RandomForest, XGBoost) 2. Calcular R^2 e RMSE para treino e teste 3. Criar uma **tabela comparativa** formatada 4. Identificar: qual modelo apresentou **maior overfitting**? qual apresentou **melhor generalização**? 5. Plotar predicted vs real para o melhor e o pior modelo (lado a lado) 6. Escrever **1 parágrafo** recomendando qual modelo você implementaria como soft-sensor — e por quê […]

Aula 06 — Avaliação e Validação de Modelos

M2 — Aprendizado de Máquina · 100 min

Objetivo. Capacitar o aluno a avaliar modelos preditivos com métricas de engenharia, diagnosticar overfitting vs underfitting e usar validação cruzada para estimar a capacidade de generalização — sempre no contexto de processos químicos.

Recurso	Onde
Notebook	`aula06_validacao.ipynb` · abrir no Colab
Dados	`aula06/` — 4 arquivos (cenários A/B/C)
Apresentação	pptx · pdf
Bloom	Lembrar → Avaliar

Sequência didática.

1. Abertura (10 min) — O Modelo É Bom o Bastante para Operar a Planta?
2. Teoria (25 min) — Métricas, Overfitting e Validação Cruzada
3. Prática (40 min) — Validando Modelos como um Engenheiro
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *Na engenharia química, errar a composição em 0,5% pode significar produto fora da especificação = R$ 500.000 de perda. Errar a temperatura em 5 °C pode ser uma explosão. Qual métrica captura o **custo** do erro?*

Tarefa pós-aula. Tarefa individual — "Relatório de Validação de Modelo" Usando o dataset **CSTR** das aulas anteriores (ou um novo de sua escolha), você deve produzir um **relatório completo de validação** no formato de notebook Colab: 1. **Seção 1 — Split e Treino:** Treine pelo menos 2 modelos (Random Forest + XGBoost) 2. **Seção 2 — Métricas:** Calcule R^2, RMSE, MAE para treino e teste — tabela formatada 3. **Seção 3 —**

Diagnóstico: A diferença $R^2_{treino} - R^2_{teste}$ indica overfitting? Justifique 4. **Seção 4 — Validação Cruzada:** k=5, reporte média ± desvio do R^2 5. **Seção 5 — […]

Aula 07 — Conceito e Projeto de Soft-Sensors

M2 — Aprendizado de Máquina · 100 min

Objetivo. Capacitar o aluno a compreender o conceito, a arquitetura e as etapas de projeto de um soft-sensor industrial — justificando sua aplicação, selecionando variáveis secundárias (features) e avaliando a viabilidade técnica vs. analisadores físicos.

Recurso	Onde
Notebook	`aula07_soft_sensors.ipynb` · abrir no Colab
Dados	**reuso** · `aula04/coluna_destilacao_30dias.csv`
Apresentação	pptx · pdf
Bloom	Lembrar → Avaliar

Sequência didática.

1. Abertura (10 min) — O Problema que Nenhum Sensor Resolve
2. Teoria (25 min) — Arquitetura e Projeto de Soft-Sensors
3. Prática (40 min) — Projetando um Soft-Sensor para Coluna de Destilação
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *Se o GC custa R$ 200k + R$ 30k/ano de manutenção, e o soft-sensor custa R$ 10k para desenvolver + R$ 1k/mês de nuvem, qual o payback? E se o erro do soft-sensor for 2% maior que o GC?*

Tarefa pós-aula. Tarefa individual — "Projeto Conceitual de um Soft-Sensor" Escolha **um processo químico** (pode ser da lista abaixo ou outro da sua escolha): - Reator CSTR — estimar conversão em tempo real - Coluna de destilação — estimar composição do produto de fundo - Trocador de calor — estimar coeficiente de incrustação (U/U_0) - Evaporador — estimar Brix (concentração) do produto Crie um **notebook Colab** com: 1. **Seção 1 — Definição:** Descreva o processo, a variável primária, a precisão requerida e a frequência desejada.

Aula 08 — Laboratório Prático 1 — Soft-Sensor

M2 — Aprendizado de Máquina · 100 min

Objetivo. Capacitar o aluno a construir, validar e documentar um soft-sensor funcional em Python — do CSV ao modelo treinado, passando por todo o pipeline de dados, features, modelagem e avaliação — entregando um notebook completo que poderia ser apresentado a um gerente de planta.

Recurso	Onde
Notebook	`Lab1_SoftSensor_Template.ipynb` · abrir no Colab · gabarito
Dados	**reuso** · `aula04/coluna_destilacao_30dias.csv`
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — Missão: Construir um Soft-Sensor Funcional
2. Setup (10 min) + Teoria Relâmpago (10 min) = 20 min
3. Prática (60 min) — Construção do Soft-Sensor (10 Células)
4. Discussão e Fechamento (20 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Tarefa pós-aula. Tarefa — "Meu Soft-Sensor do Zero" O entregável é um **notebook completo** que poderia ser apresentado a um gerente de planta. Use o **mesmo dataset** da aula ou um diferente se preferir. Seu notebook deve conter **obrigatoriamente**: 1. **Cabeçalho:** Título, autor, data, descrição do problema em 3 frases 2. **Carregamento e EDA:** info(), describe(), pairplot + heatmap + texto interpretando as correlações 3. **Limpeza e Features:** tratamento de NaN, detecção de outliers, criação de lags/médias móveis + justificativa 4. **Modelagem:** Regressão Linear, Random Forest, XGBoost — todos com [...]

Aula 09 — Introdução às Redes Neurais Artificiais

M2 — Aprendizado de Máquina · 100 min

Objetivo. Capacitar o aluno a compreender o funcionamento interno de uma rede neural artificial — neurônio, camadas, funções de ativação, feedforward e backpropagation — e implementar uma MLP simples com Scikit-Learn para predição em processo químico.

Recurso	Onde
Notebook	`aula09_redes_neurais.ipynb` · abrir no Colab
Dados	**reuso** · `aula04/coluna_destilacao_30dias.csv`
Apresentação	pptx · pdf
Bloom	Lembrar → Analisar

Sequência didática.

1. Abertura (10 min) — O Neurônio que Aprende
2. Teoria (25 min) — Do Neurônio à MLP
3. Prática (40 min) — MLP para Predição de Composição
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *Um neurônio só consegue aprender relações LINEARES. Como 3 neurônios em camada aprendem uma curva? Onde nasce a não-linearidade?*

Tarefa pós-aula. Tarefa individual — "MLP vs XGBoost para o CSTR" Usando o dataset do **reator CSTR** (das aulas anteriores): 1. Treine uma MLP com arquitetura (64, 32, 16) + ReLU, dados escalados 2. Treine um XGBoost (n_estimators=200) como baseline 3. Compare RMSE, R^2 e **tempo de treinamento** (use `%%time` na célula) 4. Plote predicted vs real para ambos (lado a lado) 5. A MLP superou o XGBoost? Quando você escolheria uma MLP vs XGBoost? **Trilha NT (desafio extra, opcional):** Teste MLPs com **1 camada oculta de tamanho variável**: `(2,)`, `(8,)`, `(32,)`, `(128,)`.

Aula 10 — Laboratório Prático 2 — Redes Neurais

M2 — Aprendizado de Máquina · 100 min

Objetivo. Capacitar o aluno a construir, treinar, avaliar e ajustar uma rede neural MLP usando Keras/TensorFlow — da definição da arquitetura ao salvamento do modelo treinado — aplicada à predição de rendimento de um reator químico.

Recurso	Onde
Notebook	`Lab2_MLP_Keras_Template.ipynb` · abrir no Colab · gabarito
Dados	`aula10/reator_rendimento.csv`
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — Do Scikit-Learn ao Keras
2. Setup + Teoria Relâmpago (20 min)
3. Prática (60 min) — Construindo uma MLP com Keras
4. Discussão e Fechamento (10 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Tarefa pós-aula. Tarefa — "MLP Keras para Coluna de Destilação" Usando o dataset `coluna_destilacao_30dias.csv`, construa uma MLP em Keras seguindo o mesmo pipeline do laboratório: 1. Features: T_top, T_base, P_coluna, R_refluxo + lags (k=1,3) + média móvel (k=5) 2. Target: composição do destilado 3. Arquitetura: você decide — tente pelo menos 2 arquiteturas diferentes 4. Compile com Adam + EarlyStopping + ReduceLROnPlateau 5. Compare com XGBoost (baseline) 6. Salve o melhor modelo como `soft_sensor_coluna.keras` 7. Conclusão: a MLP superou o XGBoost? Qual arquitetura funcionou melhor? Por quê? **Trilha […]

Aula 11 — Modelagem Híbrida e Caixa Cinza

M2 — Aprendizado de Máquina · 100 min

Objetivo. Capacitar o aluno a compreender o paradigma da modelagem híbrida (caixa cinza) — onde leis de conservação (balanços) são combinadas com modelos de ML para estimar parâmetros desconhecidos — superando as limitações de modelos puramente fenomenológicos ou puramente baseados em dados.

Recurso	Onde
Notebook	`aula11_hibrido.ipynb` · abrir no Colab
Dados	`aula11/` — 3 arquivos
Apresentação	pptx · pdf
Bloom	Lembrar → Avaliar

Sequência didática.

1. Abertura (10 min) — O Melhor dos Dois Mundos
2. Teoria (25 min) — Balanço + ML = Modelo Híbrido
3. Prática (40 min) — Modelo Híbrido de um CSTR
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *No modelo híbrido, o ML não estima a saída do processo — ele estima um parâmetro físico (k, U). O que acontece com a predição se o ML estimar k com 20% de erro? O balanço de massa 'filtra' o erro ou amplifica?*

Tarefa pós-aula. Tarefa — "Modelo Híbrido para Trocador de Calor" Um **trocador de calor casco e tubo** tem seu coeficiente global U descrito por correlações empíricas que podem estar desatualizadas devido à incrustação. O balanço de energia é:

$$Q = U \cdot A \cdot \Delta T_{ml} = \dot{m} \cdot C_p \cdot (T_{\text{saída}} - T_{entrada})$$

onde Q é a taxa de transferência, A a área, ΔT_{ml} a média logarítmica, $\dot{m}$ a vazão mássica e C_p o calor específico.

Aula 12 — Laboratório Prático 3 — Modelo Híbrido

M2 — Aprendizado de Máquina · 100 min

Objetivo. Capacitar o aluno a implementar um modelo híbrido completo — do balanço fenomenológico ao ML acoplado — validando a consistência física das predições e comparando com modelos puramente baseados em dados.

Recurso	Onde
Notebook	`Lab3_Hibrido_Template.ipynb` · abrir no Colab · gabarito
Dados	**reuso** · `aula11/cstr_hibrido.csv`
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — Missão: Implementar um Modelo Híbrido
2. Setup + Teoria Relâmpago (15 min)
3. Prática (60 min) — Construindo o Híbrido
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Tarefa pós-aula. Tarefa — "Híbrido para Trocador de Calor (completo)" Usando o dataset `trocador_hibrido_lab.csv`, implemente um modelo híbrido completo: 1. **Balanço de energia:** $Q = UA\Delta T_{ml} = \dot{m}C_p(T_{\text{saída}} - T_{entrada})$ 2. **Calcular** U_{real} dos dados 3. **Treinar ML** para estimar U a partir de $[\dot{m}, T_{entrada}]$ 4. **Acoplar:** $\hat{U} \rightarrow \hat{T}_{\text{saída}} = T_{entrada} + \frac{\hat{U}A\Delta T_{ml}}{\dot{m}C_p}$ 5. **Comparar** híbrido vs ML direto vs U constante (interpolação + extrapolação) 6. **Conclusão:** qual modelo você [...]

Aula 13 — Dinâmica de Processos e Séries Temporais

M3 — Modelagem Dinâmica · 100 min

Objetivo. Capacitar o aluno a compreender por que processos químicos são inerentemente dinâmicos (atraso, inércia, acumulação), como modelar séries temporais com features baseadas em tempo, e por que redes recorrentes (LSTM) são necessárias quando a memória do processo importa.

Recurso	Onde
Notebook	`aula13_dinamica.ipynb` · abrir no Colab
Dados	`aula13/reator_dinamico.csv`
Apresentação	pptx · pdf
Bloom	Lembrar → Analisar

Sequência didática.

1. Abertura (10 min) — O Tempo Não Para na Planta
2. Teoria (25 min) — O que Torna um Processo "Dinâmico"?
3. Prática (40 min) — Dinâmica na Prática
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *A constante de tempo τ de um CSTR é V/F. Se τ = 10 min e o atraso de transporte ϑ = 15 min, o que acontece quando você tenta controlar a composição com um PID?*

Tarefa pós-aula. Tarefa — "Identificação FOPDT de um Processo Real" Usando o dataset `reator_dinamico.csv` (dados reais de um CSTR com degraus na vazão): 1. Plote a série temporal completa — identifique os degraus 2. Isole **um degrau** e estime visualmente Kp, τ, θ (método da tangente ou 63.2%) 3. Simule um modelo FOPDT com esses parâmetros e sobreponha ao real 4. Calcule o RMSE do modelo FOPDT vs dados reais 5. Treine uma MLP com lags para predizer a saída — quantos lags usou? O RMSE da MLP é menor que o FOPDT? **Trilha NT (desafio extra, opcional):** Se o processo **não for FOPDT** (ex: segunda ordem) [...]

Aula 14 — LSTM para Predição Dinâmica

M3 — Modelagem Dinâmica · 100 min

Objetivo. Capacitar o aluno a implementar, treinar e avaliar uma rede LSTM (Long Short-Term Memory) em Keras/TensorFlow para predição de séries temporais de processos químicos — compreendendo quando e por que a LSTM supera modelos com lags fixos.

Recurso	Onde
Notebook	`aula14_lstm.ipynb` · abrir no Colab
Dados	**reuso** · `aula13/reator_dinamico.csv`
Apresentação	pptx · pdf
Bloom	Lembrar → Avaliar

Sequência didática.

1. Abertura (10 min) — A Rede que Lembra
2. Teoria (20 min) — LSTM na Prática com Keras
3. Prática (60 min) — LSTM vs MLP para o CSTR Dinâmico
4. Discussão e Fechamento (10 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Tarefa pós-aula. Tarefa — "LSTM para Coluna de Destilação" Usando `coluna_destilacao_30dias.csv` (composição do destilado como target): 1. Converta os dados em sequências (window = 60 min = 60 timesteps) 2. Treine uma LSTM (camadas: LSTM(64) → LSTM(32) → Dense(1)) 3. Treine uma MLP com 60 lags (baseline) 4. Compare RMSE (1 passo) e RMSE (10 passos) 5. Plote predição para 2h de operação (120 min) com ambos os modelos 6. Conclusão: LSTM é vantajosa para este processo? **Trilha NT (desafio extra, opcional):** Teste **2 arquiteturas LSTM** diferentes: - LSTM de 1 camada (64 células) - LSTM de 2 camadas (64 → […]

Aula 15 — Otimização de Processos com IA

M4 — Otimização, Controle e Confiabilidade · 100 min

Objetivo. Capacitar o aluno a usar modelos de ML como metamodelos (surrogate models) de processos químicos e acoplá-los a otimizadores numéricos para encontrar condições operacionais ótimas — maximizando rendimento, minimizando custo ou atendendo restrições.

Recurso	Onde
Notebook	`aula15_otimizacao.ipynb` · abrir no Colab
Dados	`aula15/cstr_rendimento.csv`
Apresentação	pptx · pdf
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — Encontrando a Agulha no Palheiro Operacional

2. Teoria (25 min) — Metamodelos e Otimização
3. Prática (40 min)
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *Otimizar o modelo vs otimizar a planta são problemas diferentes. Se o modelo erra em 2%, o ótimo encontrado é confiável?*

Tarefa pós-aula. Usando o dataset `coluna_destilacao_30dias.csv`, treine um metamodelo XGBoost para predizer composição do destilado a partir de `[R_refluxo, T_top, P_coluna]`. Otimize a razão de refluxo para maximizar pureza com restrição de custo energético (R_refluxo < 8). **Trilha NT:** Implemente otimização multiobjetivo: maximizar pureza E minimizar R_refluxo (custo). Plote a fronteira de Pareto. **Trilha SJ:** Checklist: [ ] metamodelo, [ ] função objetivo, [ ] otimização, [ ] validação, [ ] conclusão. **Entrega:** Link do Google Colab. Prazo: 7 dias. —

Aula 16 — Visão Conceitual de Controle Avançado

M4 — Otimização, Controle e Confiabilidade · 100 min

Objetivo. Capacitar o aluno a compreender a evolução do controle de processos — do PID clássico ao MPC baseado em modelo — e simular uma malha MPC com preditor ML, comparando desempenho em tracking de set-point e rejeição de perturbações.

Recurso	Onde
Notebook	`aula16_mpc.ipynb` · abrir no Colab
Dados	— (FOPDT simulado no notebook)
Apresentação	pptx · pdf
Bloom	Lembrar → Analisar

Sequência didática.

1. Abertura (10 min) — Do Retrovisor ao Para-brisa
2. Teoria (25 min) — Do PID ao MPC com ML
3. Prática (40 min)
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *O MPC 'enxerga' 30 min à frente. Se o modelo de predição erra em 10%, o MPC ainda acerta o set-point? O que acontece com a estabilidade?*

Tarefa pós-aula. Implemente um MPC que usa **um modelo LSTM** (da Aula 14) como preditor para controle de temperatura de um reator CSTR. Compare com PID. O LSTM é mais lento para avaliar — o MPC ainda roda em tempo real? (meça o tempo de cada otimização). **Trilha NT:** Adicione uma restrição de slew rate ($\Delta u_{max} = 2$) e uma restrição de temperatura máxima ($T_{max} = 200°C$). O MPC respeita as restrições? O PID consegue? **Trilha SJ:** [ ] PID implementado, [ ] MPC implementado, [ ] horizonte N testado, [ ] gráficos comparativos, [ ] conclusão. **Entrega:** Link do Google Colab. Prazo: 7 dias. —

Aula 17 — Manutenção Preditiva e RUL

M4 — Otimização, Controle e Confiabilidade · 100 min

Objetivo. Capacitar o aluno a implementar modelos de predição de falhas e estimativa de RUL usando dados históricos de degradação de equipamentos — migrando de manutenção corretiva (quebra) e preventiva (calendário) para **preditiva (baseada em condição)**.

Recurso	Onde
Notebook	`aula17_rul.ipynb` · abrir no Colab
Dados	`aula17/` — 2 arquivos
Apresentação	pptx · pdf
Bloom	Lembrar → Analisar

Sequência didática.

1. Abertura (10 min) — Trocar Cedo ou Tarde?
2. Teoria (25 min) — RUL: Quanto Tempo Antes da Falha?
3. Prática (40 min)
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *Se a incrustação acelera com o tempo (não-linear), um modelo linear de degradação subestima ou superestima a RUL? Qual o risco financeiro de cada erro?*

Tarefa pós-aula. Você recebeu dados de **vibração de uma bomba centrífuga** (6 meses até a falha). Features: RMS de vibração (mm/s), temperatura do mancal, vazão. Treine **3 modelos** para predizer RUL: 1. Regressão Linear simples (RUL = f(tempo)) 2. XGBoost (RUL = f(tempo, vibração, temp, vazão)) 3. LSTM (sequência dos últimos 30 dias) Compare MAE. **Qual modelo funciona melhor com degradação não-linear?** (a vibração acelera perto da falha) **Trilha NT:** Calcule o **intervalo de confiança de 95%** para cada predição de RUL (boostrap com 100 amostras).

Aula 18 — Detecção e Diagnóstico de Anomalias

M4 — Otimização, Controle e Confiabilidade · 100 min

Objetivo. Capacitar o aluno a implementar detectores de anomalia não-supervisionados — aprendendo o que é "normal" sem dados rotulados de falha — computar score de anomalia e calibrar um threshold, avaliar o desempenho via matriz de confusão, e diagnosticar os 4 tipos de falha mais comuns em um reator químico, equilibrando sensibilidade e especificidade.

Recurso	Onde
Notebook	`aula18_anomalias.ipynb` · abrir no Colab
Dados	`aula18/` — 2 arquivos
Apresentação	pptx · pdf
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — A Agulha no Palheiro de 10.000 Sensores
2. Teoria (25 min) — Três Formas de Detectar o Diferente
3. Prática (40 min)
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *1% de alarmes falsos em 10.000 sensores = 100 alarmes/dia. O operador vai ignorar todos em uma semana. Mas se o threshold for alto demais para evitar os falsos alarmes, uma falha real passa despercebida. Como calibrar o threshold sem ter dados rotulados?*

Tarefa pós-aula. Usando o dataset `reator_troca_calor.csv` (2 trocadores + reator, 30 dias), treine PCA, Isolation Forest e Autoencoder aprendendo apenas dados normais. Injete sinteticamente 4 falhas conhecidas (válvula presa, drift de sensor, fouling, desativação de catalisador) e avalie o F1-score de cada detector por tipo de falha. **Trilha NT:** Calibre o threshold de cada detector minimizando o custo total (defina funções de custo: falso negativo = 10× o falso positivo) e reporte o custo operacional esperado para cada configuração.

Aula 19 — Interpretabilidade e Explicabilidade (XAI)

M5 — Ciclo de Vida do Modelo · 100 min

Objetivo. Capacitar o aluno a abrir a "caixa-preta" de um modelo de ML com ferramentas de Explainable AI (XAI) — respondendo **"por que o modelo fez esta predição?"** em nível global e local — e a usar a física do processo como árbitro final: se o SHAP não concordar com a termodinâmica (ex.: sinal da temperatura em um reator), o aluno deve saber diagnosticar e corrigir (overfitting, data leakage, multicolinearidade, interações não-óbvias).

Recurso	Onde
Notebook	`aula19_xai.ipynb` · abrir no Colab
Dados	`aula19/cstr_exotermico_xai.csv`
Apresentação	pptx · pdf
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — Por que o Modelo Disse Isso?
2. Teoria (25 min) — Importância Global e SHAP Local
3. Prática (40 min)
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Tarefa pós-aula. Produza um **relatório SHAP completo** para o modelo XGBoost da **coluna de destilação** (`coluna_destilacao_30dias.csv`, pureza do destilado a partir de `[R_refluxo, T_top, P_coluna, vazao_alim]`): 1. **Summary plot** — ranking global e direção de cada feature 2. **Dependence plot** de 3 features (T_top, R_refluxo, vazao_alim) 3. **Waterfall plot** de 2 predições: uma certa (erro < 2%) e uma errada (erro 5%) 4. **Conclusão de consistência física:** o sinal do SHAP de cada feature concorda com a destilação (ex.: R_refluxo alto → maior pureza → SHAP positivo)? 5. **Diagnóstico:** se alguma […]

Aula 20 — Gêmeos Digitais, IIoT e IA Generativa

M5 — Ciclo de Vida do Modelo · 100 min

Objetivo. Capacitar o aluno a projetar conceitualmente um gêmeo digital de um processo químico (trocador de calor ou reator) — desenhando a arquitetura sensores → edge → nuvem → modelo, escolhendo protocolos IIoT, definindo critérios de validação por drift e usando LLMs como assistentes de diagnóstico e documentação de engenharia.

Recurso	Onde
Notebook	`aula20_twin_iiot.ipynb` · abrir no Colab
Dados	`aula20/trocador_e101_24h.csv`
Apresentação	pptx · pdf
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — O Espelho Digital da Planta
2. Teoria (25 min) — Arquitetura de um Gêmeo Digital
3. Prática (40 min)
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *Um twin não é uma cópia perfeita — é um modelo que se atualiza com dados em tempo real. Se a planta e o twin discordam por mais de 5% por mais de 1 h, quem está errado: o sensor, o modelo ou a planta? Como decidir se o twin precisa ser retreinado?*

Tarefa pós-aula. Produza um **documento de 1 página** propondo um gêmeo digital para um processo de sua escolha (reator CSTR da Aula 5, coluna de destilação da Aula 8, trocador E-101 da Aula 12/17, etc.). Inclua: - **Diagrama** da arquitetura: sensores → edge → nuvem → modelo → ação - **Sensores** — grandezas, range e protocolo (OPC-UA / MQTT) - **Modelo** do twin (ML / híbrido / primeiros princípios) e justificativa - **Frequência** de atualização e retreino - **Benefício estimado** (redução de parada, energia, manutenção) - **Validação** — limiar de drift (θ e τ) e o que dispara a ação **Trilha NT:** Inclua […]

Aula 21 — Desafios de Implantação e Governança de IA

M5 — Ciclo de Vida do Modelo · 100 min

Objetivo. Capacitar o aluno a conduzir um modelo de ML do protótipo validado até a operação industrial, antecipando e mitigando as barreiras técnicas, econômicas e organizacionais — qualidade de dados, conectividade e legado — por meio de um plano de implantação em 4 fases, de uma análise de ROI realista e de um framework de governança que garanta aprovação, retreino e rollback seguros.

Recurso	Onde
Notebook	`aula21_implantacao.ipynb` · abrir no Colab
Dados	`aula21/shadow_test_composicao.csv`
Apresentação	pptx · pdf
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — O Modelo Não Implanta Sozinho
2. Teoria (25 min) — As Quatro Muralhas da Implantação
3. Prática (40 min)
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar) — Plano de Implantação de 1 Página

Pergunta-desafio. *Custo do retreino mensal = R$ 5.000. Benefício = R$ 3.000/mês. O projeto é viável? O que está faltando nessa conta?*

Tarefa pós-aula. Elabore um **plano de implantação de 1 página** para um modelo de sua escolha (ex.: predição de ponto de fulgor, soft-sensor de viscosidade, MPC assistido por ML). Inclua, obrigatoriamente: 1. **As 4 fases** com risco e mitigação de cada uma 2. **Análise de ROI** em 3 cenários (otimista: 20% de redução de variabilidade; realista: 10%; pessimista: 5%) — assuma produção, preço e custos e apresente os cálculos 3. **Framework de governança**: quem aprova, frequência de retreino, e o plano de rollback com estratégia **champion/challenger** 4. **Critérios de sucesso** mensuráveis para cada fase [...]

Aula 22 — Ética, Segurança Industrial e Responsabilidade

M5 — Ciclo de Vida do Modelo · 100 min

Objetivo. Capacitar o aluno a reconhecer e mitigar vieses em dados de processo, posicionar a IA dentro da hierarquia de controle de riscos, proteger dados operacionais (OT/ICS) e empregar um framework ético (transparência, responsabilidade, robustez) para decidir quem responde por decisões automatizadas — onde um erro de modelo pode causar acidentes ambientais.

Recurso	Onde
Notebook	`aula22_etica.ipynb` · abrir no Colab
Dados	`aula22/torre_resfriamento_12m.csv`
Apresentação	pptx · pdf
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — Quem Assina a Responsabilidade?
2. Teoria (25 min) — Viés, Riscos e Ética
3. Prática (40 min)
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *Quem assina a ART (Anotação de Responsabilidade Técnica) do modelo de IA? O engenheiro de dados, o de processos, ou o gerente da planta? Soa estranho, não? Na engenharia, sempre alguém assina.*

Tarefa pós-aula. Redija um parágrafo de **"Política de Uso de IA"** para uma planta química, respondendo: quando o modelo decide sozinho? Quando o humano valida? Quem assina a responsabilidade? Que barreiras de segurança protegem a operação? Fundamente na hierarquia de controle de riscos e no framework ético (transparência, responsabilidade, robustez). **Trilha NT:** Desenhe um **fluxograma de decisão** para exceções — modelo sugere → operador valida → supervisor autoriza → registro em log. Inclua o caso do modelo que pede interromper a coluna de destilação.

Aula 23 — O Engenheiro Químico do Futuro

M5 — Ciclo de Vida do Modelo · 100 min

Objetivo. Capacitar o aluno a traçar um plano de desenvolvimento profissional realista e executável — posicionando-se frente às tendências tecnológicas e mapeando as competências (técnicas e comportamentais) necessárias para integrar IA e Engenharia Química ao longo da carreira.

Recurso	Onde
Notebook	`aula23_futuro.ipynb` · abrir no Colab
Dados	— (discussão, sem dados)
Apresentação	pptx · pdf
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — O Engenheiro Químico de Amanhã Já Está Sendo Formado Hoje
2. Teoria (25 min) — Tendências, Perfil T-Shaped e o Kit de Ferramentas do Futuro
3. Prática (40 min)
4. Discussão e Fechamento (15 min)
5. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *O EQ que sabe IA vai substituir o que não sabe? Ou a IA vai ampliar a demanda por engenheiros químicos?*

Tarefa pós-aula. Escreva uma **Carta para si mesmo (daqui a 12 meses)**: "Hoje eu sei ____. Em 12 meses quero saber ____. Para isso vou ____." Anexe seu radar de competências atual e liste **3 marcos mensais** para os primeiros 3 meses. **Trilha NT:** Pesquise **3 vagas reais de EQ + IA** no LinkedIn/Glassdoor. Liste as **habilidades pedidas em comum**.

Aula 24 — Checkpoint e Mentoria do Projeto Prático

M6 — Projeto Integrador · 100 min

Objetivo. Oferecer mentoria personalizada equipe a equipe — validar a definição do problema, a qualidade e suficiência dos dados, o baseline, o diagnóstico de overfitting e os próximos passos — destravando dificuldades técnicas e realinhando o cronograma rumo à entrega final (Etapa 2 + Apresentação nas Aulas 29-30).

Recurso	Onde
Apresentação	pptx · pdf
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — Dia de Destravar o Projeto
2. Trabalho Guiado / Mentoria Coletiva (20 min) — O Checklist de Diagnóstico
3. Rodadas de Mentoria (50 min — 5 equipes × 10 min)
4. Discussão (10 min)
5. Fechamento e Tarefa (10 min)

Pergunta-desafio. *O objetivo de hoje não é 'ver quem está adiantado' — é descobrir o que está travando cada equipe e destravar. Um projeto travado em dados é diferente de um travado em modelo: o segundo é mais fácil de resolver. Qual destravamos primeiro?*

Aula 25 — Oficina de Desenvolvimento I

M6 — Projeto Integrador · 100 min

Objetivo. Garantir, sob supervisão do professor, que todas as equipes concluam as etapas de preparação de dados (limpeza, EDA final, features) e treinem um primeiro modelo baseline com métrica documentada — desbloqueando avanços, corrigindo erros de abordagem em tempo real e validando o progresso individual de cada equipe rumo ao Projeto Integrador final.

Recurso	Onde
Apresentação	pptx · pdf
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — Meta da Oficina e Organização das Equipes
2. Trabalho Guiado — Limpeza de Dados e EDA Final (30 min)
3. Feature Engineering + Baseline com Mentoria Individual (40 min)
4. Discussão (15 min) — Checkpoint das Equipes
5. Fechamento e Tarefa (5 min)

Aula 26 — Oficina de Desenvolvimento II

M6 — Projeto Integrador · 100 min

Objetivo. Prover tempo supervisionado para as equipes treinarem e refinarem seus modelos do Projeto Integrador — com mentoria focada em validação cruzada (k-fold), diagnóstico e correção de overfitting/underfitting, refinamento de hiperparâmetros e comparação justa de arquiteturas contra o baseline da Aula 25.

Recurso	Onde
Apresentação	pptx · pdf
Bloom	Aplicar → Avaliar

Sequência didática.

1. Abertura (10 min) — Bater o Baseline
2. Treinamento e Validação Cruzada (30 min) — Bloom: Aplicar
3. Diagnóstico e Refinamento + Mentoria (35 min) — Bloom: Analisar e Avaliar
4. Discussão (13 min) — Comunitário e Avaliativo
5. Fechamento e Tarefa (12 min) — Bloom: Avaliar/Criar

Pergunta-desafio. *Um modelo com RMSE de treino muito baixo e RMSE de teste alto: ele é bom ou ruim? POR QUE o primeiro engana?*

Aula 27 — Consolidação dos Resultados do Projeto Integrador

M6 — Projeto Integrador · 100 min

Objetivo. Capacitar cada equipe a transformar notebooks técnicos em um relatório executivo claro e persuasivo — comunicando o valor do modelo construído para audiências não-técnicas (gerentes, operadores, diretoria) e preparando a apresentação final das Aulas 28–29.

Recurso	Onde
Apresentação	pptx · pdf
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — Do Notebook ao Quarto da Diretoria
2. Análise Crítica e Consolidação (20 min) — Vale a Pena Contar Essa História?
3. Relatório Executivo (Prática) (45 min) — Produção em Oficina
4. Discussão (15 min) — Compartilhando o Valor
5. Fechamento e Tarefa (10 min) — Entregáveis Fechados

Pergunta-desafio. *O gestor pergunta: 'o modelo melhorou o rendimento ou só previu melhor?'. Como você mostra o VALOR entregue — não apenas a acurácia — com os dados que você já tem?*

Aula 28 — Ensaio e Ajustes de Apresentação

M6 — Projeto Integrador · 100 min

Objetivo. Capacitar as equipes a entregar uma apresentação final clara, tecnicamente sólida e no tempo — ensaiando o pitch cronometrado, recebendo feedback estruturado (clareza, profundidade, slides, tempo) e realizando os ajustes finais no deck e no roteiro de fala.

Recurso	Onde
Apresentação	pptx · pdf
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — O Ensaio como Ensaio Geral da Apresentação Final
2. Roteiro de Apresentação (15 min) — Teoria da Comunicação Técnica
3. Ensaio Cronometrado (60 min) — 5 Equipes × 12 min de Pitch
4. Feedback e Discussão (15 min) — Avaliar e Refinar
5. Fechamento e Ajustes (20 min) — Criar a Versão Final
6. Tarefa Pós-Aula (Bloom: Criar)

Pergunta-desafio. *Um pitch excelente em slide pode falhar em 12 minutos. O que transforma um bom conteúdo em uma boa apresentação? E o reverso: um conteúdo raso pode sobreviver a perguntas difíceis?*

Tarefa pós-aula. Com o feedback recebido no ensaio, finalize o deck e o roteiro: (1) reescreva os slides que quebraram a rubrica; (2) revise a distribuição dos 12 min por seção (abertura ≤ 1 min, método ≤ 4 min, resultados ≤ 4 min, conclusão ≤ 2 min, perguntas ≤ 2 min); (3) anote as respostas às perguntas que a banca fez; (4) ensaie o pitch individualmente, cronometrando, pelo menos 2 vezes. **Trilha NT:** Prepare a resposta profunda a 3 perguntas desafiadoras: *validação do modelo*, *generalização a novos dados/condições da planta* e *custo-benefício de implantação e manutenção*.

Aula 29 — Apresentações Finais I

M6 — Projeto Integrador · 100 min

Objetivo. Avaliar a capacidade das equipes de comunicar seus projetos de IA aplicada à Engenharia Química — demonstrando clareza, profundidade técnica e análise crítica dos resultados — e dar feedback formativo que oriente as equipes restantes e o refinamento final.

Recurso	Onde
Apresentação	pptx · pdf
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (10 min) — Critérios e Logística
2. Seminário — Equipe A (28 min)

3. Seminário — Equipe B (28 min)
4. Seminário — Equipe C (28 min)
5. Encerramento do dia (6 min)
6. Tarefa Pós-Aula (Bloom: Criar)

Tarefa pós-aula. - Equipes que já apresentaram: enviar a **versão final** dos slides e do notebook até o prazo combinado, incorporando o feedback recebido. - Equipes que ainda não apresentaram: revisar os slides com base nos **critérios da rubrica** e no feedback observado nas apresentações de hoje. - **Trilha NT (todos):** preparar 2 perguntas críticas ("por que escolheu X?" / "qual a limitação de Y?") para a banca da Aula 30. - **Trilha SJ (todos):** checar a lista: [ ] slides revisados pela rubrica, [ ] tempo ≤ 15 min, [ ] notebook executável e entregue, [ ] relatório com análise crítica.

Aula 30 — Apresentações Finais II e Encerramento do Curso

M6 — Projeto Integrador · 100 min

Objetivo. Concluir as defesas dos projetos finais das equipes D e E, avaliar as apresentações com uma rubrica transparente, premiar simbolicamente os destaques, colher depoimentos que consolidam a jornada de 30 aulas e fechar o curso com uma reflexão sobre o papel do engenheiro químico na era da IA.

Recurso	Onde
Apresentação	pptx · pdf
Bloom	Lembrar → Criar

Sequência didática.

1. Abertura (5 min) — Fechando o Círculo das 30 Aulas
2. Seminário — Equipe D (30 min) — Bloom: Aplicar e Avaliar
3. Seminário — Equipe E (30 min) — Bloom: Aplicar e Avaliar
4. Premiação e Roda de Depoimentos (20 min) — Bloom: Avaliar e Criar
5. Encerramento do Curso (15 min)

Pergunta-desafio. *para a plateia: **

Rubricas de avaliação

Avaliação por **decisão**, não por acerto. Um modelo com R^2 pior e validação correta vale mais que um R^2 alto obtido com vazamento de dados — e a rubrica precisa dizer isso em voz alta, senão o aluno aprende o contrário.

> **Escala única para tudo.** Quatro níveis, mesma lógica em todos os instrumentos: **I** Insuficiente (0–39%) · **B** Básico (40–59%) · **P** Proficiente (60–79%) · **E** Exemplar (80–100%). A nota final de cada item é a média ponderada dos critérios.

---

1. Princípios que valem para todos os instrumentos

Princípio	Como aparece na correção
Justificativa vale mais que resultado	"Usei Random Forest porque reduziu RMSE de 1,4 para 0,9" (P) vs. "usei Random Forest" (B)
Faixa de validade é obrigatória	Todo modelo entregue declara onde deixa de valer. Ausência disso trava o item em B, mesmo com métrica boa
Erro diagnosticado é melhor que erro escondido	Aluno que mostra o modelo falhando fora da faixa e explica por quê chega a E
Reprodutibilidade conta	Semente fixa, ordem das células executável, nenhum resultado "escrito à mão"
Duas audiências	Relatório executivo (gestão) e pitch (pares) avaliam coisas diferentes; não são o mesmo texto em tamanhos diferentes

---

2. Laboratório 1 — Soft-sensor da coluna de destilação

Alvo declarado no notebook: **RMSE < 0,8 %** na composição. Roteiro de 10 células, cada uma vale um item do checklist.

Critério	I	B	P	E
Dados e EDA (cél. 1–2)	Não carrega ou não descreve	Carrega e mostra `head()`	Descreve distribuição e identifica problema	Relaciona a anomalia ao fenômeno de processo
Limpeza e features (cél. 3–4)	Sem tratamento	Trata NaN e outlier	Justifica o método e cria features com sentido físico	Testa alternativa e mostra o efeito na métrica
Modelagem (cél. 5–7)	Um modelo sem justificativa	Compara dois modelos	Compara e escolhe por validação adequada	Discute o que cada modelo captura e o que não captura
Métrica e gráficos (cél. 8–9)	Só imprime número	RMSE + um gráfico	Predito vs. real + resíduo	Resíduo por faixa de operação: mostra onde o modelo degrada
Conclusão (cél. 10)	Ausente	Diz se passou ou não	Explica por que passou/falhou	Declara faixa de validade e risco de implantação

Trava de nível: RMSE < 0,8 % com célula não executável ou sem semente fixa → no máximo **B**. Métrica fraca com diagnóstico honesto → **P**.

---

3. Laboratório 2 — MLP com Keras

Baseline a bater: **XGBoost, RMSE ≈ 1,5 %** no rendimento do CSTR. Roteiro de 10 células, com decisões de arquitetura registradas em markdown.

Critério	I	B	P	E
Baseline (cél. 1–4)	Não reproduz o baseline	Reproduz o XGBoost	Compara baseline e MLP na mesma partição	Explica por que a MLP supera (ou não) o ensemble
Arquitetura (cél. 5–7)	Copia do gabarito sem justificar	Define camadas e ativações	Justifica nº de camadas/neurônios e regularização	Testa duas arquiteturas e mostra o efeito
Treino	Sem `validation_split` ou early stopping	Usa validação	Curva de aprendizado analisada	Detecta overfitting pela curva e corrige
Escalonamento	Não normaliza	Normaliza entrada	Normaliza e discute por que importa	Mostra o que acontece sem normalizar
Avaliação e conclusão	Só `evaluate()`	RMSE no teste	Comparação com baseline + leitura crítica	Declara onde a rede perde para o XGBoost e por quê

Trava de nível: modelo salvo `.keras` sem versão do TensorFlow registrada → máximo **P**. Rede que só funciona na faixa de treino, sem que o aluno perceba → **B**, mesmo com RMSE bom.

---

4. Laboratório 3 — Modelo híbrido (caixa-cinza)

O checklist do template tem 8 itens objetivos. A rubrica avalia **o que o checklist não vê**.

Item do checklist	O que se exige para P
Balanço de massa escrito	Equação correta, com hipóteses declaradas (estado estacionário, mistura perfeita)
Parâmetro `k` identificado	Isola `k` algebricamente, sem erro de manipulação
`k_real` calculado	Usa os dados para obter o valor de referência
ML treinado para `k`	Modela `k` em função de variáveis de processo, com validação
Acoplamento implementado	Balanço + ML produzem `C_A` conjuntamente
Comparação com caixa branca e preta	Três modelos na mesma partição de teste
Interpolação + extrapolação	Testa **fora** da faixa de treino e reporta o que acontece
Conclusão	Diz onde o híbrido ganha e onde perde

Nível	Descrição
I	Falta o balanço ou o parâmetro não foi isolado
B	Checklist completo, mas sem comparação entre os três modelos
P	Comparação completa em interpolação, conclusão coerente
E	Mostra o híbrido **extrapolando melhor** que a caixa-preta e explica o motivo físico

O nível **E** deste laboratório é o mais valioso do curso: é o único momento em que o aluno vê o conhecimento de processo valendo mais que o dado bruto.

---

5. Projeto integrador (aulas 24–30)

Entrega: notebook + relatório executivo (2 páginas) + pitch de 12 min.

Critério	Peso	I	B	P	E
Formulação do problema	20%	Tema genérico (“IA na indústria”)	Problema definido, sem métrica	Problema, variável-alvo e métrica de sucesso explícitos	Além disso, declara o custo do erro e quem usa o resultado
Dados e validação	25%	Sem separação treino/teste	Separação aleatória	Validação temporal ou por campanha	Discute vazamento e mostra que evitou
Modelagem	20%	Um modelo, sem baseline	Baseline + modelo	Comparação justa, escolha argumentada	Ablação: mostra qual feature/etapa realmente importa
Análise crítica	25%	Só reporta métrica	Reconhece limitação	Faixa de validade e modo de falha	Propõe monitoramento e critério de retreino
Comunicação	10%	Relatório confuso	Relatório legível	Executivo claro para não especialista + pitch técnico	Defende escolhas sob arguição sem ler slides

Trava de nível: projeto sem variável-alvo mensurável → máximo **B**, independente da qualidade do código. É a falha mais comum e a mais grave: modelo sem alvo é exercício, não engenharia.

---

6. Tarefas pós-aula

Correção binária, com uma ressalva:

- **Aceito**: entrega o que foi pedido, executável, com as observações em markdown.
- **Não aceito**: notebook que não roda, ou observações ausentes.
- **Bônus (0,5 ponto)**: quando a trilha NT (desafio extra) foi feita **e** a justificativa física está correta. Não dê bônus por “fez mais exercício”; dê por raciocínio de processo.

25 das 30 aulas têm tarefa; as aulas 24–27 e 30 são oficinas e não têm.

---

7. Política de uso de IA generativa

Isto precisa estar na ementa no primeiro dia, não no edital de recurso.

Permitido: usar assistente de código para sintaxe, depuração e explicação de erro. **Permitido com declaração:** usar IA para gerar rascunho de código, desde que o aluno registre em markdown o que pediu e

o que mudou. **Não aceito:** entregar análise que o aluno não sabe defender sob arguição. A defesa oral não é punição — é o instrumento que distingue "usei ferramenta" de "não fiz".

Critério objetivo: se o aluno não consegue explicar por que escolheu uma métrica, o item de *análise crítica* cai para **I**, mesmo que o notebook execute perfeitamente.

---

8. Fechamento da nota

Instrumento	Peso
Laboratórios 1–3	30 % (10 % cada)
Projeto integrador	40 %
Tarefas pós-aula	20 %
Participação e discussão	10 %

A participação é medida pelo que o aluno **contesta** nas aulas 19–23 (governança, ética, risco): pergunta que expõe uma premissa vale mais que resposta certa.

Armadilhas

Este é o capítulo que não existe na literatura. Monografias de machine learning em engenharia química não contam o que dá errado em sala; material de didática não sabe o que é um PIMS. O que segue vem de duas fontes, e a distinção importa:

Marca	Significado
[verificado]	Fato observado no material deste repositório, com evidência rastreável
[risco]	Modo de falha previsível no desenho do curso — mitigação recomendada, sem alegar que já ocorreu

---

1. Armadilhas verificadas no próprio material

1.1 O Colab esconde dependências que o ambiente local cobra

[verificado] A aula 05 quebrava com `ImportError: Import tabulate failed`, na chamada `df.to_markdown()`. No Colab funcionava, porque `tabulate` já vem instalado na imagem. Num ambiente limpo — o de qualquer professor que clone o repositório — quebrava na nona célula.

Por que isso importa mais do que parece: o erro não aparece para você, aparece para quem adota o material. É a diferença entre "funciona" e "funciona na minha máquina".

O que fazer: antes de publicar qualquer notebook, rode em ambiente limpo. Aqui: `pip install -r requirements.txt` e execute todos. O repositório documenta o resultado: 26 notebooks, 517 células, 9,7 min, mediana de 9,7 s por notebook.

1.2 Dependência de URL crua do GitHub

[verificado] Os notebooks carregam dados por `raw.githubusercontent.com/...` — 18 URLs distintas. Não há cópia local: se o repositório mudar de nome, for tornado privado, ou a branch `main` for renomeada, **toda a turma perde os dados na mesma aula**.

O que fazer: antes de cada semestre, abra um notebook qualquer e rode a primeira célula. Custa 20 segundos. Se for lecionar offline, clone o repositório e troque `BASE` por caminho local.

1.3 O gabarito é público

[verificado] Os três laboratórios existem em duas versões no repositório público: `LabN_*_Template.ipynb` (lacunas) e `LabN_*_Gabarito.ipynb` (resolvido). A busca do GitHub encontra os dois.

Consequência: se a nota do laboratório for só "o notebook executa e o RMSE bate", parte da turma entrega o gabarito. Você vai corrigir uma cópia.

O que fazer — três opções, em ordem de preferência:

1. **Avalie por arguição**, não por arquivo: 5 min por dupla, com o notebook aberto, pedindo "por que essa métrica?" e "o que acontece se eu dobrar a vazão?". O gabarito não responde.
2. **Troque o alvo**: mantenha o template e mude a semente do dataset ou a variável-alvo (composição do topo → do fundo). O gabarito deixa de servir e o lab continua o mesmo.
3. **Use o gabarito como material de estudo** e avalie em sala, sem entrega domiciliar.

1.4 Slides uniformes não são slides rasos — mas exigem o notebook ao lado

[verificado] São 27 decks com 265 slides: 10 por aula, quase todos sem imagem (só a Aula 02 tem duas capturas de tela). Lidos isoladamente, parecem finos.

O que isso significa na prática: o slide é **âncora de condução** — pergunta-desafio, diagrama, enunciado do exercício. O conteúdo executável está no notebook. Professor que tentar dar a aula só pelos slides vai passar 40 minutos explicando o que os alunos deveriam estar fazendo.

O que fazer: trate o deck como roteiro de fala e o notebook como o material. Se quiser slides mais densos para outro público (extensão, pós-graduação), o material dos planos de aula é a fonte.

1.5 Placeholder de autor no rodapé

[verificado] 26 dos 27 decks tinham `Prof. [Seu Nome]` no rodapé; só a Aula 01 estava personalizada. Corrigido aqui, mas o padrão se repete em qualquer material gerado a partir de template.

Por que vale mencionar num capítulo de armadilhas: material publicado com placeholder de autor anuncia que nunca foi finalizado. Quem avalia adoção — coordenador, parecerista, colega — vê isso antes de ver qualquer conteúdo.

O que fazer: antes de publicar um lote, busque tokens entre colchetes em todos os arquivos. Atenção: `[1, 2, 3]`, `['col']` e `[h_{t-1}, x_t]` são notação legítima de código e matemática — não são placeholders.

1.6 PDF e PPTX saem de sincronia

[verificado] O repositório mantém as duas versões de cada deck. Editar o `.pptx` e esquecer o PDF cria divergência silenciosa: o aluno projeta uma versão, o professor edita outra.

Mitigação já implementada: `atualizar-pdfs.sh` converte só os decks cuja data é mais nova que a do PDF. Detalhe contraintuitivo: **regerar um deck inalterado ainda aparece como alteração no git**, porque o PDF carrega data de criação nos metadados. Use `--dry-run` antes de commitar em lote.

---

2. Riscos de condução

2.1 Turma heterogênea em programação

[risco] O modo de falha clássico: 20 % da turma termina o exercício em 10 min e fica ociosa; 30 % não sai da primeira célula e desiste na Aula 04.

Mitigação que funciona sem criar duas disciplinas: pareamento fixo (quem já programa com quem não), por todo o semestre. O exercício guiado tem gabarito no notebook; o aluno que trava copia a célula e segue, sem parar a aula. A avaliação é individual (arguição), o que impede carona.

Sinal de alarme: se na Aula 05 mais de um terço da turma não executou a célula 9, pare e refaça o básico de Pandas antes de avançar para modelos.

2.2 O bloco prático come sem o tempo de discussão

[risco] A aula tem 40 min de prática e 15 de discussão. Quando o Colab demora ou um aluno trava, o professor rouba da discussão — e a discussão é onde o julgamento crítico se forma.

Mitigação: cronômetro visível, e a regra de ouro — **a discussão não é cortada, a prática é encerrada onde estiver**. Um exercício inacabado com discussão feita vale mais que o contrário.

2.3 A aula 07 é a que estoura o tempo

[verificado] `aula07_soft_sensors.ipynb` leva 186 s para executar — 20 vezes a mediana dos demais. É a única que treina vários modelos em sequência.

Mitigação: rode-a antes da aula e deixe os resultados em cache no Colab, ou divida a turma em duplas com uma máquina por dupla. Em notebook de aluno com 4 GB de RAM, pode passar de 5 min.

2.4 Overfitting que passa no gabarito

[risco] Os laboratórios têm metas numéricas (RMSE < 0,8 % no Lab 1; bater o XGBoost no Lab 2). Meta numérica convida ao ajuste cego: o aluno otimiza até passar, sem validar. O modelo decora a faixa de treino e o número fica bonito.

Mitigação: a rubrica trava o nível quando falta faixa de validade declarada (ver `rubricas.md`). E cobre **extrapolação** no Lab 3 — o único laboratório em que o aluno vê o modelo falhando fora da faixa e precisa explicar por quê.

2.5 Vazamento temporal em features de lag

[risco] A Aula 03 ensina lags e médias móveis. É onde o vazamento nasce: usar média móvel centrada, ou normalizar antes de dividir treino/teste, contamina o resultado. O aluno acerta por acidente e aprende o método errado.

Mitigação: peça sempre a ordem das operações — dividir primeiro, normalizar depois, com os parâmetros do treino. Um gráfico de resíduo no tempo expõe o vazamento melhor que qualquer métrica.

2.6 Dataset sintético é mais fácil que planta real

[risco] Os 34 arquivos são gerados com seed fixa e fenômenos plantados. Isso dá reprodutibilidade, mas cria um mundo mais limpo que a planta: menos variável não medida, menos atraso variável, menos sensor

mentindo ao mesmo tempo.

Mitigação: diga isso em voz alta na Aula 01. E use a Aula 21 (governança, drift) para mostrar o que muda quando o processo envelhece. Aluno que sai achando que dado industrial é organizado vai sofrer no primeiro estágio.

---

3. Falhas de desenho a corrigir se você adotar o material

Item	Situação	O que fazer
Caminhos de dataset	O README já apontou para pastas inexistentes (corrigido na v1.1.0)	Confira todo caminho citado contra `dados/` antes de publicar sua versão
Aulas 24–30	São oficinas, sem tarefa nem dataset	Não procure material que não existe; são condução de projeto
Aula 16 (MPC)	O notebook simula o FOPDT inline; o CSV existe como apoio	Se quiser dados reais de malha aberta, use o CSV — mas o notebook não o carrega
Aulas 05, 07, 08, 09	Reutilizam o dataset da Aula 04 de propósito	Não "conserte" isso criando dataset novo: a repetição é o método
Peso da participação	10 % é frágil de medir	Substitua por arguição curta registrada em planilha, ou zere e redistribua

---

4. Checklist antes do primeiro dia

- ☐ Rode `pip install -r requirements.txt` e execute um notebook em ambiente limpo
- ☐ Abra a primeira célula de cada notebook que vai usar — as URLs de dados respondem?
- ☐ Verifique se a turma tem acesso ao Colab com a conta institucional (bloqueio de domínio é comum)
- ☐ Decida agora como vai avaliar os laboratórios **sabendo que o gabarito é público**
- ☐ Coloque a política de uso de IA generativa na ementa, não no edital de recurso
- ☐ Rode `atualizar-pdfs.sh` se editou alguma apresentação
- ☐ Leia a aula 07 antes das outras: é a que exige mais preparo técnico