Estrutura e Tratamento de Dados Industriais

Aula 02 — Limpando dados reais de planta

Outliers • Dados faltantes • Ruído • Pipeline de limpeza

Prof. Luis Vasconcelos | Duração: 100 min

Dados Reais São Imperfeitos

Qual desses gráficos você confiaria para treinar um modelo?

A — Dados Crus (direto do PIMS)

- Picos abruptos (125 °C, 45 °C)
- Lacunas (sensor offline)
- Ruído excessivo (vibração)
- Drift lento (descalibração)

B — Dados Tratados (prontos pro modelo)

- Sem picos espúrios
- NaNs preenchidos (forward fill)
- Ruído suavizado (média móvel)
- Sinal limpo e confiável

⚠ **"Dados industriais são como amostras de laboratório — se a amostra está contaminada, a análise não vale nada."**

Pergunta Desafio

"Se 30% dos dados de um sensor estão corrompidos, você descarta o sensor inteiro ou tenta recuperar?
Qual o limite aceitável?"

💡 Pense no trade-off: descartar dados = perder informação. Manter dados ruins = modelo enviesado.

Os 3 Inimigos dos Dados Industriais

Dados Faltantes (NaN)

Sensor offline
Manutenção
Falha de comunicação

Outliers

Picos espúrios (mau contato)
Eventos reais (válvula de alívio)
Erros de transcrição

Ruído

Vibração mecânica
Interferência elétrica
Resolução do sensor

Cada tipo de anomalia exige uma técnica diferente de tratamento.

Detectando Outliers — Duas Abordagens

Z-Score (distribuição normal)

$$Z_i = (x_i - \mu) / \sigma$$

$$\text{Outlier se } |Z_i| > 3$$

- Bom para dados simétricos e gaussianos
- Sensível a outliers extremos (μ e σ distorcem)
- Use quando a variável tem distribuição conhecida

IQR (robusto, sem suposições)

$$IQR = Q3 - Q1$$

$$\text{Limites: } [Q1 - 1.5 \cdot IQR,\ Q3 + 1.5 \cdot IQR]$$

- Robusto — mediana não é afetada por outliers
- Funciona para qualquer distribuição
- Recomendado para dados de processo industriais

👉 Na prática: use IQR para dados de planta. Reserve Z-score para variáveis com distribuição comprovadamente normal.

4. Exemplo Prático Concreto

Coloque um conjunto de dados pequeno no quadro (ex: notas de uma prova de 0 a 100):

$$20, 60, 65, 70, 75, 80, 85, 90, 150$$

(Note que 20 é muito baixo e 150 é um erro, pois a prova vai até 100).

Use uma tabela comparativa rápida para guiar o cálculo com eles:

Etapa	Cálculo	Resultado
Mediana (Q_2)	Valor central da lista ordenada	**75**
Q_1	Mediana da primeira metade (20, 60, 65, 70)	**62.5**
Q_3	Mediana da segunda metade (80, 85, 90, 150)	**87.5**
IQR	$Q_3 - Q_1 = 87.5 - 62.5$	**25**
Margem de Filtro	$1.5 \times IQR = 1.5 \times 25$	**37.5**

Agora, aplique as fronteiras com a turma:

- **Limite Mínimo:** 62.5 - 37.5 = **25**
- **Limite Máximo:** 87.5 + 37.5 = **125**

Conclusão com os alunos:

- O aluno que tirou **20** está exatamente no limite, então não é tecnicamente um outlier (é só uma nota muito baixa).
- O valor **150** passou de 125, logo, é um **outlier**. Provavelmente foi um erro de digitação do professor!

Tratando NaN e Suavizando Ruído

Dados Faltantes (NaN)

- <5% missing → dropna() (descartar linhas)
- Série temporal → ffill() (forward fill)
- Lacunas curtas → interpolate()
- >30% missing → repensar: sensor confiável?

Suavização de Ruído

- Média móvel: rolling(window).mean()
- Filtro mediano: rolling(window).median()
- Janela pequena (5-10): preserva dinâmica
- Janela grande (50+): destrói sinal útil!

⚠ **Cuidado: suavizar demais é como colocar óculos com grau errado — você enxerga menos, não mais.**

Pipeline de Limpeza — 7 Passos

①	`df.info()`	Identificar tipos e NaN
②	`df.isnull().sum()`	Quantificar missing por coluna
③	`df.ffill()`	Preencher NaN (série temporal)
④	`df['col'].plot.box()`	Inspeção visual de outliers
⑤	`IQR / Z-score`	Calcular limites e criar máscara
⑥	`df.loc[mask] = med`	Substituir outliers pela mediana
⑦	`rolling(5).mean()`	Suavizar ruído com média móvel

Prática: Limpando Dados do Trocador de Calor

Cenário: Sensor de T_saída com leituras estranhas. Limpe os dados!

- Carregue trocador_calor_24h_sujo.csv
- Diagnostique NaN → preencha com ffill()
- Detecte outliers com IQR em T_saida
- Substitua outliers pela mediana
- Suavize com rolling(5).mean()
- Plote antes e depois lado a lado

```
# Pipeline de limpeza
Q1 = df['T_saida'].quantile(0.25)
Q3 = df['T_saida'].quantile(0.75)
IQR = Q3 - Q1
outliers = (df['T_saida'] < Q1-1.5*IQR) | (df['T_saida'] > Q3+1.5*IQR)
df.loc[outliers, 'T_saida'] = df['T_saida'].median()
df['T_saida_suave'] = df['T_saida'].rolling(5).mean()
```

🔍 Diagnóstico Comparativo — 4 Cenários

Grupo A

15% NaN em rajadas

Arquivo: variante_A
4 falhas de sensor

1) Técnica adequada?
2) Impacto se usar a errada?
3) 1 min de apresentação

Grupo B

Outlier extremo

Arquivo: variante_B
T_saida = 250 °C

1) Técnica adequada?
2) Impacto se usar a errada?
3) 1 min de apresentação

Grupo C

Ruído alta freq.

Arquivo: variante_C
±5 °C de amplitude

1) Técnica adequada?
2) Impacto se usar a errada?
3) 1 min de apresentação

Grupo D

Drift lento

Arquivo: variante_D
0.5 °C/h descalibração

1) Técnica adequada?
2) Impacto se usar a errada?
3) 1 min de apresentação

🧠 Desafio: O outlier é evento real ou falso positivo? Como diferenciar sem perguntar ao operador?

📋 Tarefa: Meu Pipeline de Limpeza

- Baixe um dataset público de processo e corrompa intencionalmente
- Adicione: 2% NaN, 3 outliers, ruído gaussiano (σ = 2%)
- Crie notebook: diagnóstico → limpeza → antes/depois
- Escreva: "Se eu não tivesse limpo, meu modelo seria ___ porque ___"
- Entregue via Colab — Prazo: antes da Aula 4 (7 dias)

Critérios: Diagnóstico (25%) • Pipeline justificado (25%) • Gráficos (25%) • Reflexão (25%)

🧠 Bônus NT: Compare Z-score vs IQR — um detecta eventos que o outro perde? Por quê? (+20%)

Próxima aula: Engenharia de Features — lags, médias móveis, taxas de variação. 🚀