Engenharia de Features Industriais

Aula 03 — Lags, médias móveis e alinhamento temporal

Lags • Médias Móveis • Taxa de Variação • Resample

Prof. Luis Vasconcelos | Duração: 100 min

O Que o Passado Diz Sobre o Futuro?

A — T_top vs Composição (sem lag)

- Temperatura de TOPO agora
- Composição de SAÍDA agora
- Correlação fraca (R ~ 0.2)
- Por quê? O processo tem atraso!

B — T_top(lag 3) vs Composição

- Temperatura de 30 min atrás
- Composição de AGORA
- Correlação forte (R ~ 0.7)
- O lag captura a dinâmica!

"Um modelo sem lags é surdo à dinâmica do processo."

Pergunta Desafio

"Se a temperatura de topo agora afeta a composição daqui a 3 minutos, qual o lag ideal? E se o processo tem atraso de transporte de 7 minutos?"

💡 Pense: o tempo de residência do reator determina o lag relevante.

Três Tipos de Features Temporais

Lag (Defasagem)

X_{t-k} = valor k passos atrás

Ex: T_reator_lag1 = T de 10 min atrás

Captura: memória do processo

Média Móvel

$\bar{X}_t$ = média dos últimos n valores

Ex: T_reator_ma5 = média(últimos 5)

Captura: tendência recente

Taxa de Variação

$\Delta X_t = X_t - X_{t-1}$

Ex: dT = T_atual − T_anterior

Captura: velocidade de mudança

Autocorrelação — Escolhendo os Lags Certos

- ACF mede: quão similar X(t) é com X(t-k)?
- ACF alto no lag k → aquele lag contém informação
- ACF baixo → o lag não ajuda (ruído)
- Regra prática: use lags onde ACF > 1.96/√N (95% confiança)

Como interpretar o ACF de uma variável de processo:

Exemplo: T_reator de um CSTR (τ = 12 min, amostragem 10 min)

```
Lag 1 (10 min):  ACF = 0.85 → MUITO informativo (dentro do tempo de residência)
Lag 2 (20 min):  ACF = 0.60 → informativo (ainda relevante)
Lag 3 (30 min):  ACF = 0.25 → pouco informativo (fora da janela dinâmica)
Lag 7 (70 min):  ACF = 0.02 → ruído (descartar)
```

Alinhamento de Taxas Mistas — Resample

Problema: 2 Frequências

- Sensor T_reator: 1 leitura/min
- Laboratório conversão: 1 leitura/10 min
- → 10 linhas de sensor para 1 de lab
- Não dá para modelar diretamente!
- Precisamos alinhar as escalas temporais

Solução: Resample (downsample)

- df.resample('10min').mean()
- Média de 10 leituras de sensor = 1 valor
- Agora: 1 linha de sensor = 1 de lab
- join() → DataFrame único alinhado
- Perdemos resolução, ganhamos consistência

```
# Resample para 10 min
df_proc_10min = df_proc.resample('10min').mean()

# Juntar com target do laboratório
df = df_proc_10min.join(df_lab, how='inner')
```

Pipeline de Feature Engineering — 7 Passos

①	**Identificar frequência**	`1 min (sensor), 10 min (lab)`
②	**Resample**	`df.resample('10min').mean()`
③	**Criar lags**	`shift(1), shift(2), shift(3)`
④	**Média móvel**	`rolling(3).mean()`
⑤	**Taxa de variação**	`diff() – derivada discreta`
⑥	**Combinar**	`Features + target → 1 DF`
⑦	**Validar**	`dropna(), verificar leakage`

Prática: Features para um Reator CSTR

Cenário: CSTR de etoxilação — sensor (1/min) + lab (1/10min). Crie um soft-sensor!

- Carregue cstr_processo_1min.csv e cstr_lab_10min.csv
- Alinhe com resample('10min').mean()
- Crie lags de T_reator: shift(1), shift(2), shift(3)
- Crie média móvel: rolling(3).mean()
- Crie taxa de variação: diff()
- Repita para vazão de alimentação
- Combine tudo + target (conversão) em 1 DataFrame

```
df['T_reator_lag1'] = df['T_reator'].shift(1)
df['T_reator_ma3']  = df['T_reator'].rolling(3).mean()
df['dT_reator']       = df['T_reator'].diff()
```

🔍 Selecionando as Melhores Features

- Calcule df.corr()['conversao'].sort_values(ascending=False)
- Identifique as 5 features mais correlacionadas com a conversão
- Para cada uma: 1 frase explicando por que faz sentido fisicamente
- Há alguma feature que você esperava no top-5 e não está? Por quê?

🧠 Desafio NT: Se τ = 12 min e amostragem = 10 min,
o lag k=2 (20 min) captura mais ou menos informação que k=1 (10 min)?

☐ alinhamento temporal OK ☐ lags criados ☐ médias móveis ☐ taxa de variação
☐ matriz de correlação ☐ top-5 identificadas ☐ 1 parágrafo de interpretação

📋 Tarefa: Feature Engineering para Trocador de Calor

- Carregue dados do trocador (30s) + coeficiente_U (semanal)
- Alinhe: agregue features por semana
- Crie ≥ 6 features (lags, médias, derivadas)
- Calcule correlação com coeficiente_U
- Identifique top-3 features e justifique (1 parágrafo)
- Plote: coeficiente_U real vs. feature mais correlacionada
- Entregue via Colab — Prazo: antes da Aula 4 (7 dias)

🧠 Bônus NT: EWMA (média móvel exponencial) vs. média simples — qual captura melhor a incrustação? (+20%)

Próxima aula: Análise Exploratória e Visualização — heatmaps, scatter plots, séries temporais. 🚀