Análise Exploratória e Visualização (EDA)

Aula 04 — O Raio-X dos dados antes da modelagem

Histograma • Boxplot • Scatter • Pairplot • Heatmap

Prof. Luis Vasconcelos | Duração: 100 min

Uma Imagem Vale Mil Dados

A — Tabela de Números

- 500 linhas × 8 colunas
- 4.000 números para ler
- T_reator e conversão são correlacionadas?
- Impossível ver o padrão...

B — Pairplot + Heatmap

- Heatmap: R = -0.87 entre T e conversão
- Pairplot: relação linear clara
- Boxplot: outliers visíveis
- O padrão salta aos olhos!

"Sem EDA, você modela no escuro."

Pergunta Desafio

"Se o heatmap mostra correlação zero entre pressão e temperatura, mas a termodinâmica (PV=nRT) diz que P e T estão relacionadas... o que está errado?"

💡 Pense: escala dos dados? Feature transformada? Relação não-linear?

O Kit de Ferramentas da EDA

Histograma + KDE

Como os dados se distribuem? Normal? Bimodal? Assimétrica?

Boxplot

Há outliers? A variável é simétrica? Comparar escalas.

Série Temporal

Tendência? Sazonalidade? Drift? Estacionariedade.

Scatter + Regressão

Duas variáveis têm relação linear? R forte ou fraco?

Pairplot

Visão geral de TODAS as relações lineares de uma vez.

Heatmap

Grau da relação (R de Pearson). Mapa do tesouro numérico.

Interpretação do R de Pearson

$\|R\| = 0.0 - 0.3$	Fraco / Nenhuma
$\|R\| = 0.3 - 0.5$	Moderada fraca
$\|R\| = 0.5 - 0.7$	Moderada
$\|R\| = 0.7 - 0.9$	Forte
$\|R\| = 0.9 - 1.0$	Muito forte

⚠ CAVEAT: R mede apenas relação LINEAR!
Duas variáveis podem ter relação não-linear forte e R ≈ 0.
→ Sempre olhe o scatter plot antes de confiar no R.

Por que Visualizar? — Quarteto de Anscombe

4 datasets com EXATAMENTE a mesma média, variância, correlação e reta de regressão.

Estatísticas idênticas: $\bar{x}=9$, $\bar{y}=7.5$, $R=0.816$, $R^2=0.667$, $y = 3 + 0.5x$

Mas os gráficos são RADICALMENTE diferentes — linear, não-linear, outlier, vertical.

Moral: SEMPRE olhe os dados visualmente antes de confiar em estatísticas resumo.

Na engenharia química, isso significa:
- Não confie apenas em df.describe() — plote histogramas
- Não confie apenas em df.corr() — plote scatter plots
- Não confie apenas em R^2 — verifique resíduos

Roteiro de EDA — 6 Passos

①	**Visão geral**	`df.info()` · `df.describe()` · `df.shape`
②	**Univariada**	`histplot()` · `boxplot()`
③	**Série temporal**	`df[col].plot()` — tendência, drift
④	**Bivariada**	`regplot()` · `scatter()` — pares candidatos
⑤	**Multivariada**	`pairplot()` — varredura geral
⑥	**Heatmap**	`heatmap(df.corr())` — resumo numérico

Prática: EDA Completa de uma Coluna de Destilação

30 dias de operação — 8 variáveis, ~43.000 pontos. Execute o roteiro EDA!

- Carregue coluna_destilacao_30dias.csv
- Gere histogramas + KDE das 4 variáveis principais
- Boxplot comparativo
- Série temporal de 3 dias
- Pairplot (corner) + Heatmap com anotações
- Escreva 1 observação por gráfico

```
sns.heatmap(df.corr(), annot=True, fmt='.2f', cmap='RdBu', center=0)
sns.pairplot(df, vars=cols, corner=True, kind='reg')
sns.histplot(df['T_top_C'], bins=50, kde=True)
```

🔍 Diagnóstico Visual por Período

Grupo A

Semana 1

Operação normal
Estado estacionário

1) Heatmap do período
2) Compare com o geral
3) Representativo para modelo?

Grupo B

Semana 2

Start-up
Após parada programada

1) Heatmap do período
2) Compare com o geral
3) Representativo para modelo?

Grupo C

Semana 3

Perturbação
Mudança de especificação

1) Heatmap do período
2) Compare com o geral
3) Representativo para modelo?

Grupo D

Semana 4

Drift / Incrustação
Degradação lenta

1) Heatmap do período
2) Compare com o geral
3) Representativo para modelo?

🧠 Desafio NT: Qual período descartar para não enviesar o modelo? Por quê?

📋 Tarefa: Relatório de EDA de um Processo

- Escolha um dataset industrial (Kaggle/UCI ou da aula)
- Crie notebook com 5 seções: visão geral, distribuições, séries, correlações, conclusão
- Gere ≥ 6 gráficos com legendas e títulos
- Explique fisicamente as 3 correlações mais fortes
- Conclusão: 3 parágrafos (processo bem operado? target? features?)
- Entregue via Colab — Prazo: antes da Aula 5 (7 dias)

🧠 Bônus NT: Decomposição sazonal com seasonal_decompose — ciclos diários/semanais? (+20%)

Próxima aula: Nosso primeiro modelo preditivo — Regressão Linear, Árvores de Decisão! 🚀