Avaliação e Validação de Modelos

Aula 06 — Métricas, overfitting e validação cruzada

MAE • RMSE • R^2 • Overfitting • k-fold

Prof. Luis Vasconcelos | Duração: 100 min

O Modelo É Bom o Bastante para Operar a Planta?

Qual modelo você implantaria na planta?

Modelo A — Parece incrível

- R^2 treino = 0.98
- R^2 teste = 0.60
- Diferença = 0.38 (!)
- Parece melhor... MAS

🔴 **Decora os dados de treino.**
Na planta real, falha.

Modelo B — Parece modesto

- R^2 treino = 0.78
- R^2 teste = 0.76
- Diferença = 0.02
- Parece pior... MAS

✅ **Generaliza bem.**
Na planta real, funciona.

"O gap entre treino e teste é o verdadeiro teste do modelo."

Pergunta Desafio

"Na engenharia química, errar a composição em 0,5% = R$ 500.000 de perda.
Errar a temperatura em 5 °C = explosão.
Qual métrica captura o CUSTO do erro?"

💡 MAE = erro médio | RMSE = amplifica erros grandes

Três Métricas, Três Histórias

MAE

Erro Médio Absoluto

$MAE = (1/n)\ \Sigma|y_i - \hat{y}|$

"Em média, o modelo erra por X"

Penaliza todos igualmente.
Fácil de interpretar.

RMSE

Erro Quadrático Médio

$RMSE = \sqrt{[(1/n)\ \Sigma(y - \hat{y}_i)^2]}$

Amplifica erros grandes.
Se RMSE >> MAE → outliers.
O engenheiro observa PRIMEIRO.

R^2

Variância Explicada

$R^2 = 1 - SS_res/SS_tot$

"O modelo explica X% da variação"

R^2=0.85 = explica 85%
Não diz nada sobre erros absolutos.

Overfitting vs Underfitting

🔴 Overfitting (Decorar)

- ► R^2_treino ≫ R^2_teste (gap > 0.15)
- ► Modelo complexo demais para os dados
- ► Funciona no treino, falha na planta
- ► Solução: reduzir complexidade, aumentar dados, regularizar

🟡 Underfitting (Subaprender)

- ► R^2_treino baixo E R^2_teste baixo
- ► Modelo simples demais
- ► Não captura o padrão dos dados
- ► Solução: mais complexidade, mais features, modelo não-linear

✅ **Ideal: R^2_treino alto, R^2_teste alto, gap pequeno (< 0.05)**

Gráfico de Resíduos — O Detector de Mentiras

Bom — Resíduos Aleatórios

- Pontos espalhados sem padrão
- Média ≈ 0 em toda a faixa
- Modelo captura bem a relação
- Não há viés sistemático

Ruim — Padrão nos Resíduos

- Forma de funil (heterocedasticidade)
- Tendência linear (falta de feature)
- Curvatura (relação não-linear)
- Modelo está "cego" para algo

"Se os resíduos têm padrão, o modelo tem um defeito escondido."

Validação Cruzada (k-fold) — O Teste de Estresse

- Dividir dados em k partes (folds) iguais
- Treinar em k-1 folds, testar no restante
- Repetir k vezes (cada fold é teste uma vez)
- Média dos k R^2 = estimativa robusta da generalização
- Desvio padrão = quão consistente o modelo é
- Recomendado: k=5 ou k=10

```
cv_scores = cross_val_score(model, X, y, cv=5, scoring='r2')
print(f'R² CV: {cv_scores.mean():.4f} ± {cv_scores.std():.4f}')

Se R²_cv ≈ R²_teste → modelo é consistente.
Se R²_cv ≪ R²_teste → split foi "sortudo" (otimismo).
```

Pipeline de Validação — 5 Passos

①	**Split**	`train_test_split(X, y, test_size=0.2)`
②	**Métricas**	`MAE, RMSE, R² no teste`
③	**Diagnóstico**	`diff = R²_tr − R²_te → over/under`
④	**k-fold**	`cross_val_score(cv=5) → média ± std`
⑤	**Gráficos**	`predicted vs real + resíduos`

Prescrição de Melhoria por Diagnóstico

Grupo A: Overfitting

Reduzir max_depth, regularizar, aumentar dados

Grupo B: Underfitting

Mais features, modelo não-linear, reduzir regularização

Grupo C: OK

Testar XGBoost, features não-lineares, ensemble

Grupo D: Overfitting Ext.

Mesmo que A + verificar data leakage

Para cada grupo: implemente 1 ação → meça novo R^2 → a melhoria foi significativa?

📋 Tarefa: Relatório de Validação de Modelo

- Use o dataset CSTR (features + conversão)
- Treine 2 modelos: Random Forest + XGBoost
- Calcule R^2, RMSE, MAE (treino e teste)
- Diagnostique overfitting (diferença treino-teste)
- Execute k-fold (k=5) e reporte média ± desvio
- Plote predicted vs real + gráfico de resíduos
- Escreva conclusão: modelo seguro para implantar?
- Entregue via Colab — Prazo: antes da Aula 7 (7 dias)

Bônus NT: Validation curve variando max_depth (1-20) — identifique o ponto ótimo de complexidade (+20%)

Próxima aula: Soft-Sensors — do dado bruto ao modelo implantado! 🚀