Dinâmica de Processos e Séries Temporais

Aula 13 — Atraso, inércia e introdução às LSTM

FOPDT • τ, θ, Kp • Lags • LSTM

Prof. Luis Vasconcelos | Duração: 100 min

O Tempo Não Para na Planta

Até agora: cada linha é INDEPENDENTE. Mas a composição de agora responde à vazão de ATRÁS.

Instantâneo

Sensor rápido
responde na hora

Atraso (θ)

Composição muda
após 10 min

Inércia (τ)

Temperatura sobe
com atraso de 1ª ordem

"Qual desses um MLP ou XGBoost aprende SEM lags?" — apenas o instantâneo.

Pergunta Desafio

**"A constante de tempo τ = V/F de um CSTR é 10 min.
Se o atraso de transporte θ = 15 min,
o que acontece quando você tenta controlar
a composição com um PID?"**

💡 Pense: se θ > τ, o controlador 'briga' com o atraso → instabilidade.

Modelo FOPDT — Primeira Ordem + Atraso

$$\tau \cdot dy/dt + y = Kp \cdot u(t-\theta)$$

"O cavalo de batalha do engenheiro de processos — descreve 80% dos processos químicos."

τ — Constante de tempo

Inércia — CSTR: τ = V/F

θ — Atraso de transporte

Tempo do fluido na tubulação

Kp — Ganho

Variação da saída por unidade de entrada

Por que a MLP Falha em Dinâmica?

- MLP não tem MEMÓRIA
- Para capturar dinâmica, precisa de lags (U_{t-1}, U_{t-2}...)
- Se θ = 15 min e amostragem = 1 min → precisa de 15 lags
- Com 15+ lags, a MLP sofre com maldição da dimensionalidade
- Quantos lags? Você precisa SABER (θ + 3τ)

LSTM resolve: memória interna aprende quantos passos de história importam.

MLP + Lags vs LSTM

Aspecto	MLP + Lags	LSTM
Memória	Explícita (você define lags)	Interna (aprende)
Nº lags p/ θ=15	15+ features (maldição)	Nenhum lags explícito
Overfitting	Alto com muitos lags	Controlável
Dinâmica longa	Difícil	Natural
Tuning	Escolher nº de lags	Escolher janela/épocas

Pipeline para Modelagem Dinâmica

①	**Dinâmico?**	Série temporal tem tendência?
②	**Estimar θ, τ**	Visual na resposta ao degrau
③	**Criar lags**	Até θ + 3τ
④	**Lags demais?**	→ usar LSTM (memória)
⑤	**Validar**	Predição multi-passos

Prática: Simular FOPDT + MLP com Lags

Cenário: CSTR com τ=10min, θ=5min. Vazão varia em degraus aleatórios.

- Carregue reator_dinamico.csv (simulado FOPDT)
- Plote F e CA — identifique visualmente θ e τ
- Crie lags de F: shift(1), 5, 10, 15, 20
- Treine MLPRegressor com os lags
- Calcule RMSE — quantos lags necessários?

```
for lag in [1, 5, 10, 15, 20]:
    df[f'F_lag{lag}'] = df['F'].shift(lag)

mlp = MLPRegressor(hidden_layer_sizes=(32, 16), max_iter=500)
```

Quantos Lags? — 4 Grupos

Grupo A

Lags:
[1, 2, 3]

θ = 5 min

Qual grupo tem menor RMSE?
Quando o ganho satura?

Grupo B

Lags:
[1, 5, 10, 15, 20]

θ = 5 min

Qual grupo tem menor RMSE?
Quando o ganho satura?

Grupo C

Lags:
[1, 5, 10, 15, 20, 30, 40]

θ = 5 min

Qual grupo tem menor RMSE?
Quando o ganho satura?

Grupo D

Lags:
[1, 5, 10, 15, 20]

θ = 15 min

Qual grupo tem menor RMSE?
Quando o ganho satura?

🧠 Desafio: E se θ=30min? → 30 lags → LSTM faz sentido.

📋 Tarefa: Identificação FOPDT de um Processo Real

- Carregue reator_dinamico.csv (degraus na vazão)
- Plote a série — identifique os degraus
- Isole UM degrau e estime Kp, τ, θ (tangente / 63.2%)
- Simule FOPDT com esses parâmetros e sobreponha ao real
- Calcule RMSE do FOPDT vs dados
- Treine MLP + lags — a MLP é melhor que o FOPDT?
- Entregue via Colab — Prazo: antes da Aula 14 (7 dias)

Bônus NT: O processo NÃO é FOPDT (2ª ordem)? Use scipy find_peaks p/ oscilações → frequência natural, amortecimento (+20%)

Próxima aula: Lab — LSTM com Keras para predizer dinâmica do CSTR! 🚀