LSTM para Predição Dinâmica

Aula 14 — A rede que lembra

Memória interna • Gates • Multi-passo

Prof. Luis Vasconcelos | Duração: 100 min

O Problema da MLP + Lags

- MLP não tem memória — precisa de lags explícitos
- Se θ = 30 min, precisa de 30 features
- Maldição da dimensionalidade!
- Número de lags é FIXO (definido manualmente)
- Para θ longo ou variável, vira um problema

Solução LSTM: memória INTERNA (c_t) que aprende quantos passos de história importam — sem lags explícitos.

Pergunta Desafio

"A LSTM com 10 células de memória tem MENOS parâmetros que uma MLP com 30 lags, mas performance igual ou melhor.
Onde está a inteligência que economiza parâmetros?"

💡 Pense: a LSTM reutiliza o estado — não redescobre cada lag.

A LSTM — Como um Operador Experiente

"Ele não olha 30 manômetros separados — desenvolveu uma MEMÓRIA INTERNA: 'a última vez que a vazão caiu, a composição demorou 30 min para responder'."

🧠 Forget gate

O que ESQUECER da memória anterior

✍ Input gate

O que ADICIONAR de novo

📤 Output gate

O que PASSAR para a saída

📦 Cell state

A memória de longo prazo

O Funcionamento da Célula

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

$$h_t = o_t \odot \tanh(c_t)$$

$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$ (idem i_t, o_t, $\tilde{c}_t$ via σ/tanh)

No Keras, isso é UMA linha: layers.LSTM(64)

Preparando os Dados Sequenciais

Ao invés de (X_t, y_t) estático, usamos janelas temporal:

```
(x_{t-29}, ..., x_t)  →  y_{t+1}        (janela de 30 timesteps)
```

Formato 3D para a LSTM:

```
(amostras, timesteps, features)    ex: (970, 30, 2)
```

Validação Temporal (não aleatória!)

- Séries temporais: split por POSIÇÃO, não aleatório
- 70% treino → 15% validação → 15% teste (em ordem)
- Evita DATA LEAKAGE (treino vendo o futuro)
- Teste = período que o modelo NUNCA viu

```
tr = int(0.7·n); va = int(0.85·n)
X_tr = X[:tr];  X_te = X[va:]
```

Pipeline LSTM no Keras — 5 Passos

①	**Sequências**	`timeseries_dataset / sliding_window_view`
②	**Definir**	`LSTM(64) → Dropout → Dense(1)`
③	**Compilar**	`Adam(0.001), loss='mse'`
④	**Treinar**	`EarlyStopping(patience=10)`
⑤	**Avaliar**	`compare com MLP + lags`

Gabarito: LSTM vs MLP

Modelo	RMSE 1 passo	RMSE 10 passos	Parâmetros
MLP + 30 lags	~0.06-0.08	~0.20-0.30	~2000
LSTM (64)	~0.04-0.06	~0.12-0.18	~17000

LSTM supera em 1 passo e MUITO em multi-passo (erro acumula menos).

⚠ Mas NÃO é sempre superior: processo estático ou atraso pequeno → MLP+lags empata/ganha (menos parâmetros, mais rápida).

📋 Tarefa: LSTM para Coluna de Destilação

- Use coluna_destilacao_30dias.csv (composição como target)
- Converta em sequências (window = 60 min)
- Treine LSTM(64)→LSTM(32)→Dense(1)
- Treine MLP com 60 lags (baseline)
- Compare RMSE 1 passo e 10 passos
- Plote predição para 2h de operação
- Entregue via Colab — Prazo: antes da Aula 15 (7 dias)

Bônus NT: LSTM 1 camada vs 2 camadas (+ Dropout) — qual para multi-passo? (+20%)

Próxima aula: Otimização de Processos com IA! 🚀