Otimização de Processos com IA

Aula 15 — Metamodelo + Otimizador

Metamodelo • Função objetivo • Otimizadores • Pareto

Prof. Luis Vasconcelos | Duração: 100 min

Encontrando a Agulha no Palheiro

Modelos PREDIZEM. Mas como DECIDIR o melhor ponto de operação?

🎯 Objetivo

Maximizar rendimento, minimizar custo, atender restrições

🗺️ Metamodelo

ML que aproxima a superfície de resposta (avaliação rápida)

Otimizador

scipy.optimize procura o ponto ótimo sem testar 10.000 na planta

"Como encontrar o ponto ótimo sem testar 10.000 combinações na planta?"

Pergunta Desafio

"Otimizar o modelo e otimizar a planta são problemas DIFERENTES.
Se o modelo erra em 2%, o ótimo encontrado é confiável?"

💡 Pense: o otimizador pode explorar onde o modelo 'alucina'.

O Metamodelo (Surrogate Model)

"É como um simulador de voo: não é o avião real, mas é barato e seguro para testar manobras. O otimizador encontra a melhor rota sem arriscar a planta."

- Modelo de ML aproxima a resposta do processo
- RF, XGBoost, MLP treinados em dados da planta
- Avaliação RÁPIDA e BARATA (vs planta real)
- Substitui a planta na busca do ótimo
- O ótimo final ainda precisa ser VALIDADO

Função Objetivo e Restrições

$$\min \; f_{obj}(T, P) = -\text{Rendimento}(T, P)$$

(negativo porque otimizadores MINIMIZAM)

Restrições (limits operacionais):

$$70 \leq T \leq 130\ ^\circ C \qquad 5 \leq P \leq 12\ \text{bar} \qquad \Delta T_{max} \leq 5\ ^\circ C/\text{min}$$

Escolhendo o Otimizador

Nelder-Mead	Simplex, sem gradiente	Local, simples
BFGS	Baseado em gradiente	Rápido, mas ótimo LOCAL
differential_evolution	Evolucionário, global	**Robusto p/ não-convexo**
SHGO	Global	**Bom p/ espaços pequenos**

📌 **Para superfícies não-convexas (comuns em processos), o evolucionário é mais seguro.**

Pipeline — 5 Passos

①	**Metamodelo**	`RandomForestRegressor(200)`
②	**Objetivo**	`fun = lambda x: -model.predict([x])[0]`
③	**Restrições**	`bounds=[(70,130), (5,12)]`
④	**Otimizar**	`differential_evolution(fun, bounds)`
⑤	**Validar**	`superfície 3D + simulação/planta`

Comparando Métodos — 4 Grupos

Grupo A	Grupo B	Grupo C	Grupo D
Nelder-Mead	**BFGS**	**differential_evolution**	**SHGO**
Qual ótimo encontrou? Convergiu rápido? Parou em local?	Qual ótimo encontrou? Convergiu rápido? Parou em local?	Qual ótimo encontrou? Convergiu rápido? Parou em local?	Qual ótimo encontrou? Convergiu rápido? Parou em local?

🧠 **Por que o BFGS para em local e o differential_evolution acha o global?**

O Perigo de Otimizar o Modelo

- Otimizador pode explorar região onde o modelo ALUCINA
- O ótimo 'perfeito' pode ser um pico estreito do modelo (não da planta)
- Se o modelo erra 2%, o ótimo real desloca
- MITIGAÇÃO: buscar região PLANA e robusta, não o pico
- SEMPRE validar: simulação + plano de testes na planta

📌 **Valide o ótimo em uma GRADE mais fina do modelo antes de aplicar na planta.**

📋 Tarefa: Otimizar a Coluna de Destilação

- Use coluna_destilacao_30dias.csv
- Metamodelo XGBoost: pureza = f(R_refluxo, T_top, P_coluna)
- Otimize R_refluxo p/ maximizar pureza
- Restrição: R_refluxo < 8 (custo energético)
- Valide o ótimo na superfície do modelo
- Entregue via Colab — Prazo: antes da Aula 16 (7 dias)

Bônus NT: Multiobjetivo — maximizar pureza E minimizar refluxo. Plote a fronteira de Pareto (+20%)

Próxima aula: Controle Preditivo (MPC) — modelos dentro da malha de controle! 🚀