Detecção e Diagnóstico de Anomalias

Aula 18 — Sem rótulos, só o padrão "normal"

PCA • Isolation Forest • Autoencoder • Threshold

Prof. Luis Vasconcelos | Duração: 100 min

A Agulha no Palheiro de Sensores

Supervisionado precisa de rótulos. E se NUNCA houve uma falha para rotular?

Painel de 2 anos de um reator:

- 99.5% pontos normais (azul)
- 0.5% falhas de 4 tipos (vermelho)

**Solução: detectores NÃO-supervisionados aprendem o padrão "normal"
e disparam quando algo FOGEM dele — sem saber qual é cada falha.**

Pergunta Desafio

"1% de alarmes falsos em 10.000 sensores = 100 alarmes/dia.
O operador vai ignorar todos em uma semana.
Mas se o threshold for alto demais,
uma falha real passa despercebida.
COMO calibrar sem dados rotulados?"

💡 Simulação com falhas injetadas + custo (falso negativo > falso positivo).

Detector 1: PCA

- Projeta nas direções de maior variância (componentes)
- Q-residual: distância PERPENDICULAR ao hiperplano
- T^2 de Hotelling: valores extremos no hiperplano
- Rápido, linear, interpretável
- Ponto cego: anomalia na direção dos scores parece 'normal'

$Q = \|x - \hat{x}\|^2$ (residual fora do modelo) $T^2 = t^T \Lambda^{-1} t$ (distância no modelo)

Detector 2: Isolation Forest

- Partição aleatória em árvores
- Anomalias isoladas em POUCOS splits (caem em região vazia rápido)
- Score = 2^(−h/c) — profundidade média de isolamento
- Robusto, não-linear, eficiente em alta dimensão
- Falha: anomalia numa região densa (start-up) não é isolada

```
s(x) = 2^(-h(x)/c̄)  — quanto menor, mais isolado = mais anômalo
```

Detector 3: Autoencoder

- Rede neural encod + decod (comprime e reconstrói)
- Treinada SÓ com dados normais
- Anomalia = ALTO erro de reconstrução
- Poderoso e não-linear — detecta evoluções lentas
- Precisa de ~10k+ amostras normais; difícil interpretar

```
Erro = ‖x − dec(enc(x))‖²   — a rede não reconstrói padrões que nunca viu
```

Pipeline — 5 Passos

①	**Treinar**	cada detector SÓ com dados normais
②	**Score**	Q / profundidade / erro de reconstrução
③	**Threshold**	percentil 95, 99 ou 99.5 do treino
④	**Classificar**	score > threshold = anomalia
⑤	**Avaliar**	matriz de confusão vs falhas conhecidas

Sensibilidade × Especificidade

🔍 Sensibilidade

Threshold baixo
detecta mais falhas
mas FALSOS ALARMES

🎯 Especificidade

Threshold alto
evita falsos alarmes
mas FALHAS PASSAM

📌 **Custo do FALSO NEGATIVO (acidente/parada) costuma superar o FALSO POSITIVO (alarme ignorado)**

Qual Detector Detecta Qual Falha?

Método	1. Válvula	2. Drift	3. Fouling	4. Catalisador	F1
PCA	✅	✅	❌	✅	~0.60
Isolation Forest	❌	❌	❌	✅	~0.40
Autoencoder	✅	✅	✅	✅	~0.85

Autoencoder é o mais completo — detecta evoluções lentas (fouling, catalisador).

📋 Tarefa: Detectores em Trocadores

- reator_troca_calor.csv: 2 trocadores + reator, 30 dias
- Treine PCA, IF e Autoencoder só com dados normais
- Injete 4 falhas sintéticas (válvula, drift, fouling, catalisador)
- Avalie F1 por detector e por tipo de falha
- Entregue via Colab — Prazo: antes da Aula 19 (7 dias)

Bônus NT: Calibre o threshold minimizando custo (FN = 10× FP). Reporte custo por configuração.

Próxima aula: Reconfiguração de processo em tempo real (MPC em cenários de falha)! 🚀