Interpretabilidade e Explicabilidade (XAI)

Aula 19 - Por que o modelo disse isso?

SHAP • Feature Importance • Validação Física

Prof. Luis Vasconcelos | Duração: 100 min

O Caso do Lote Rejeitado

O XGBoost previu rendimento em 91.3%. Mas POR QUE? Qual sensor empurrou a predição?

- Modelo preciso mas SILENCIOSO (caixa-preta)
- IA rejeitou lote por qualidade; operador perguntou 'por quê?'
- Sem resposta -> desligou o modelo, voltou ao manual
- Fábrica perdeu ~R$200 mil/mês de economia

“O modelo precisa apenas ACERTAR, ou também EXPLICAR?”

Pergunta Desafio

"Se o SHAP diz que T reator contribuiu POSITIVAMENTE para o rendimento, mas a termodinâmica diz que T acima do ótimo REDUZ conversão... o modelo está errado? Ou o SHAP capturou uma INTERAÇÃO não-óbvia?"

A física é o árbitro final: se conflita, o modelo está sob suspeita.

Feature Importance Global

MDI (Gini)

- Queda média de impureza nas árvores
- Favorece cardinalidade alta
- NÃO mostra sinal

Permutation

- Embaralha coluna e mede queda de score
- Mais confiável (efeito real)
- Custosa; sensível a correlacionadas

Ambas são GLOBAIS - não explicam uma predição específica (para isso, SHAP local).

SHAP - Shapley Values

- Contribuição marginal justa de cada feature
- Média sobre TODAS as ordenações possíveis
- Orçamento fechado: soma dos SHAP = predição − média
- Explica uma predição individual (LOCAL)

$$\Sigma\ \varphi j = \hat{y} - \bar{y} \qquad \text{(nada some, nada aparece do nada)}$$

Os 3 Gráficos do SHAP

Summary

Importância global + direção (cor = valor da feature)

Dependence

SHAP vs valor da feature -> linear, não-linear ou limiar

Waterfall

Uma predição decomposta; barras empurram p/ cima ou baixo

Se T reator alta -> SHAP positivo até o ótimo, depois negativo (exotérmico), a física está representada.

Pipeline XAI - 6 Passos

- **@1** Treinar modelo
- **@2** TreeExplainer
- **@3** Summary plot (global)
- **@4** Dependence (T,P)
- **@5** Waterfall (2 predições)
- **@6** Validar física

```
explainer = shap.TreeExplainer(modelo);  shap_values = explainer(X_test)
```

Prática: SHAP no Reator Exotérmico

- Treine XGBoost (rendimento = f(T,P,C_feed,vazão))
- TreeExplainer -> summary plot
- Dependence de T e P - C sinO?
- Waterfall de 1 predição certa e 1 errada
- Conclua: modelo é fisicamente consistente?

Gabarito: T SHAP + até ~105°C depois - (sino); P +; C_feed -; vazão -

Diagnóstico com Waterfall - 4 Grupos

Cada grupo investiga 1 predição SUSPEITA (erro > 5%) de viscosidade de resina. O waterfall revela a causa.

- Feature dominante no erro?
- Sinal vs lei física (conversão alta -> viscosidade alta -> SHAP +)
- Classifique: overfitting / data leakage / colinearidade / interação
- Proponha 1 correção (drop coluna, mais dados, regularizar)

💡 Se timestamp/id_lote tem SHAP alto = DATA LEAKAGE -> dropar e re-treinar.

📋 Tarefa: Relatório SHAP da Coluna

- Use coluna_destilacao_30dias.csv (pureza)
- Summary plot + dependence (T_top, R_refluxo, vazão)
- Waterfall de 2 predições (certa e errada)
- Conclua consistência física (R_refluxo alto -> pureza -> SHAP +)
- Diagnostique inconsistências
- Entregue via Colab - Prazo: antes da Aula 20 (7 dias)

🔍 NT: Compare SHAP vs permutation importance p/ T e R. Divergência = correlacionadas?

Próxima aula: Gêmeos Digitais, IIoT e LLMs! 🚀